



**Universidad  
Europea**

**UNIVERSIDAD EUROPEA DE MADRID**

**ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO**

**MÁSTER UNIVERSITARIO EN ANÁLISIS DE DATOS MASIVOS (BIG DATA)**

**TRABAJO FIN DE MÁSTER**

**ESTUDIO PREDICTIVO DE PRODUCCIÓN DE  
PETRÓLEO Y GAS, Y SUS APLICACIONES EN EL  
PRECIO**

**JOHAN MAURICIO SUAREZ DAZA**

**Dirigido por**

**DR. ALVARO CALLE CORDON**

**CURSO 2024-2025**

---

**TÍTULO:** ESTUDIO PREDICTIVO DE PRODUCCIONES DE PETRÓLEO Y GAS, Y SUS APLICACIONES EN EL PRECIO

**AUTOR:** JOHAN MAURICIO SUAREZ DAZA

**TITULACIÓN:** MÁSTER UNIVERSITARIO EN ANÁLISIS DE DATOS MASIVOS (BIG DATA)

**DIRECTOR DEL PROYECTO:** DR. ALVARO CALLE CORDON

**FECHA:** MARZO DE 2026

## RESUMEN

El presente trabajo de investigación aborda la problemática de la predicción de producción y precios de commodities energéticos en Colombia, específicamente para crudo y gas, utilizando técnicas avanzadas de Machine Learning y series temporales. La investigación se fundamenta en datos históricos de producción proporcionados por la Agencia Nacional de Hidrocarburos (ANH) y precios de referencia internacional obtenidos de la Federal Reserve Economic Data (FRED), comprendiendo el periodo 2014-2025. La metodología implementada se estructuró en varias fases, primero la construcción de una arquitectura en AWS siguiendo patrones de diseño medallion, garantizando la calidad, trazabilidad y disponibilidad de los datos; un análisis exploratorio profundo que reveló una baja correlación entre producción y precios, finalmente una implementación y comparación de múltiples enfoques predictivos incluyendo modelos estadísticos, Machine Learning y Deep Learning.

Los resultados obtenidos demostraron la superioridad consistente de modelos de Machine Learning en todos los casos, modelos tradicionales presentaron un desempeño pobre y los modelos de Deep Learning, aunque eran arquitectónicamente avanzados, no lograron superar los modelos de Machine Learning, esto debido al volumen de datos limitados. Las principales contribuciones de esta investigación incluye el desarrollo de una metodología robusta para predicción de series temporales energéticos que integra análisis exploratorio profundo, detección de cambios estructurales y feature engineering; la documentación y análisis de un cambio estructural significativo en la relación crudo-gas con implicaciones para la modelización multivariante, estableciendo referencias para futuras investigaciones en el sector y la entrega de modelos predictivos operativos con métricas de error cuantificada, listos para su implementación en entornos productivos. Se concluye que los modelos de Machine Learning, con feature engineering evita el data leakage, constituye la herramienta más versátil, precisa y confiable para la predicción de variables energéticas en el contexto colombiano. Se recomienda implementar los modelos seleccionados con reentrenamiento y monitoreo continuo de correlaciones para mantener su precisión ante eventuales nuevos cambios estructurales en el mercado.

**Palabras clave:** Producción, Petróleo, Gas, Commodities, precios, machine Learning, modelos predictores, ANH, FRED, forecasting, arquitectura medallion, series temporales, AWS, análisis exploratorio.

## ABSTRACT

This research paper addresses the issue of predicting energy commodity production and prices in Colombia, specifically for crude oil and gas, using advanced machine learning and time series techniques. The research is based on historical production data provided by the National Hydrocarbons Agency (ANH) and international reference prices obtained from the Federal Reserve Economic Data (FRED), covering the period 2014-2025. The methodology implemented was structured in several phases, first the construction of an architecture in AWS following medallion design patterns, ensuring the quality, traceability, and availability of the data; an in-depth exploratory analysis that revealed a low correlation between production and prices; and finally, an implementation and comparison of multiple predictive approaches including statistical models, machine learning, and deep learning.

The results obtained demonstrated the consistent superiority of machine learning models in all cases. Traditional models performed poorly, and deep learning models, although architecturally advanced, failed to outperform machine learning models due to the limited volume of data. The main contributions of this research include the development of a robust methodology for energy time series prediction that integrates in-depth exploratory analysis, structural change detection, and feature engineering; the documentation and analysis of a significant structural change in the crude-gas relationship with implications for multivariate modeling, establishing references for future research in the sector; and the delivery of operational predictive models with quantified error metrics, ready for implementation in production environments.

It is concluded that machine learning models with feature engineering prevent data leakage and constitute the most versatile, accurate, and reliable tool for predicting energy variables in the Colombian context. It is recommended to implement the selected models with retraining and continuous monitoring of correlations to maintain their accuracy in the face of possible new structural changes in the market.

**Keywords:** Production, Oil, Gas, Commodities, prices, machine learning, predictive models, ANH, FRED, forecasting, medallion architecture, time series, AWS, exploratory analysis.

## **AGRADECIMIENTOS**

Primeramente, a mi esposa, quien me ha apoyado desde el día en que mi anhelo era cursar una maestría para poder avanzar en mi carrera, por sus ánimos en todo momento , en los momentos donde he sentido que no podría responder con todo , trabajo y estudios.

También a mis profesores, por sus conocimientos, por la paciencia y el esfuerzo que hicieron que esta maestría valiera cada esfuerzo, por enseñar con la dedicación de formar profesionales que van más allá en el campo laboral y finalmente a mi tutor por su guía en este TFM y estar pendiente de cada proceso y dificultad que se han presentado durante el desarrollo del proyecto.

---

*"La información es el petróleo del siglo XXI, y la analítica es el motor de la combustión."*

**Peter Sondergaard**, vicepresidente Senior, Gartner

## TABLA RESUMEN

|                                                                               | DATOS                                                                                                                                                                                                                                       |
|-------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Nombre y apellidos:                                                           | JOHAN MAURICIO SUAREZ DAZA                                                                                                                                                                                                                  |
| Título del proyecto:                                                          | ESTUDIO PREDICTIVO DE PRODUCCIONES DE PETROLEO Y GAS, Y SUS APLICACIONES EN EL PRECIO                                                                                                                                                       |
| Directores del proyecto:                                                      | DR. ALVARO CALLE CORDON                                                                                                                                                                                                                     |
| El proyecto ha implementado un producto:                                      | NO                                                                                                                                                                                                                                          |
| El proyecto ha consistido en el desarrollo de una investigación o innovación: | SI                                                                                                                                                                                                                                          |
| Objetivo general del proyecto:                                                | Desarrollar una arquitectura end-to-end para poder tener data de producción de crudo y gas en Colombia, junto con sus precios y poder ser consumidos para crear modelos predictivos de los mismos para analizar con precios internacionales |

# Índice

|                                                                         |    |
|-------------------------------------------------------------------------|----|
| RESUMEN.....                                                            | 3  |
| ABSTRACT .....                                                          | 4  |
| AGRADECIMIENTOS.....                                                    | 5  |
| TABLA RESUMEN.....                                                      | 7  |
| Índice .....                                                            | 8  |
| Índice de Figuras.....                                                  | 11 |
| Índice de Tablas .....                                                  | 13 |
| Capítulo 1. INTRODUCCIÓN .....                                          | 14 |
| Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE.....                         | 16 |
| 2.1 Predicción de precios y optimización de Trading .....               | 16 |
| 2.2 Optimización y estrategia .....                                     | 17 |
| 2.3 Plataforma de datos para decisiones Upstream.....                   | 17 |
| 2.4 Servicios de AWS para análisis de Commodities .....                 | 18 |
| Capítulo 3. OBJETIVOS .....                                             | 19 |
| 3.1 Objetivo general .....                                              | 19 |
| 3.2 Objetivos específicos .....                                         | 20 |
| Capítulo 4. METODOLOGÍA.....                                            | 22 |
| 4.1 Metodología del proyecto .....                                      | 22 |
| 4.1.1 Fase 1: Definición del Proyecto y análisis .....                  | 22 |
| 4.1.2 Fase 2: Diseño e implementación de la arquitectura de datos ..... | 23 |
| 4.1.3 Fase 3: Análisis exploratorio EDA: .....                          | 23 |
| 4.1.4 Fase 4: Modelo predictivo .....                                   | 24 |
| 4.1.5 Fase 5. Análisis de resultados y visualización .....              | 24 |
| CAPITULO 5. DESARROLLO E IMPLEMENTACIÓN .....                           | 26 |
| 5.1 Introducción al desarrollo.....                                     | 26 |
| 5.2 Implementación de la Arquitectura de Datos en AWS.....              | 26 |
| 5.2.1. Configuración del Data Lake .....                                | 27 |
| 5.2.2. Ingesta de Datos a la capa Bronze .....                          | 29 |
| 5.2.3 Transformaciones a la capa Silver .....                           | 29 |



---

|                                                                        |    |
|------------------------------------------------------------------------|----|
| 5.2.4 Construcción de modelo dimensional .....                         | 30 |
| 5.2.5 Implementación del Data Warehouse.....                           | 32 |
| 5.2.6 Resumen de la implementación .....                               | 33 |
| 5.3 Análisis Exploratorio de Datos (EDA) .....                         | 34 |
| 5.3.1 Carga y análisis inicial .....                                   | 34 |
| 5.3.2 Análisis de relación entre Producción y Precio.....              | 35 |
| 5.3.3 Análisis de evolución de la Producción de Petróleo (Crudo) ..... | 37 |
| 5.3.4 Análisis de evolución de la Producción Gas.....                  | 42 |
| 5.3.5 Conclusiones del Análisis Exploratorio .....                     | 48 |
| 5.3.6 Análisis de Precios .....                                        | 49 |
| 5.4 Modelos de Predicción (Producción).....                            | 54 |
| 5.4.1 Modelos de Predicción Crudo.....                                 | 54 |
| 5.4.2 Modelos de Predicción Gas .....                                  | 59 |
| 5.5 Modelos de Predicción (Precios Commodities).....                   | 63 |
| 5.5.1 Predicción precio crudo .....                                    | 63 |
| 5.6 Resultados Modelos Predicción.....                                 | 70 |
| 5.6.1 Resultados Predicción Crudo .....                                | 71 |
| 5.6.2 Resultados Predicción Gas.....                                   | 74 |
| 5.6.3 Resultados Predicción Precio Crudo .....                         | 76 |
| 5.6.4 Resultados Predicción Precio Gas.....                            | 78 |
| 5.6.5 Resultados Predicción Precio Gas.....                            | 81 |
| 5.7 Proyecciones y Decisiones .....                                    | 81 |
| 5.7.1 Metodología para la generación de predicciones .....             | 82 |
| 5.7.2 Resultados de las Predicciones 12 Meses.....                     | 82 |
| 5.7.3 Construcción de Escenarios .....                                 | 89 |
| 5.7.3 Impactos Económicos de los Escenarios.....                       | 92 |
| CAPITULO 6. DISCUSION .....                                            | 98 |
| 6.1 Resultados Principales .....                                       | 98 |
| 6.2 Limitaciones del Estudio .....                                     | 98 |
| 6.2.1 Limitaciones por Disponibilidad de Datos .....                   | 98 |
| 6.2.3 Limitaciones por Factores Externos.....                          | 99 |

---

|                                                               |     |
|---------------------------------------------------------------|-----|
| 6.3 Adaptaciones Metodológicas .....                          | 99  |
| 6.2.1 Cambio de Multivariantes a Univariante en Precios ..... | 99  |
| 6.2.2 Evolución del Análisis de Escenarios.....               | 100 |
| 6.2.2 Impacto de los Resultados.....                          | 100 |
| CAPITULO 7. CONCLUSIONES.....                                 | 101 |
| 7.1 Análisis Exploratorio de Datos .....                      | 101 |
| 7.2 Modelos de Predicción Producción .....                    | 101 |
| 7.3 Modelos de Predicción Precios.....                        | 102 |
| 7.4 Hallazgos Importantes .....                               | 103 |
| 7.5 Predicción con Modelos Ganadores .....                    | 103 |
| 7.5.1 Tendencias de Producción 12 Meses .....                 | 104 |
| 7.5.2 Estacionalidad Capturada .....                          | 104 |
| 7.5.3 Validez de la Proyecciones.....                         | 104 |
| 7.6 Conclusiones Personales.....                              | 105 |
| CAPITULO 8. FUTURAS LINEAS DE TRABAJO.....                    | 107 |
| 8.1 Análisis con Datos Internos de Operadoras.....            | 107 |
| 8.2 Automatización y Operaciones.....                         | 108 |
| 8.3 Análisis de Impacto Económico y Social .....              | 108 |
| Bibliografía .....                                            | 109 |

## Índice de Figuras

|                                                                                               |    |
|-----------------------------------------------------------------------------------------------|----|
| Ilustración 1: Metodología – Elaboración Propia .....                                         | 22 |
| Ilustración 2: Arquitectura AWS – Elaboración Propia .....                                    | 27 |
| Ilustración 3: Estructura Data Lake - Elaboración Propia.....                                 | 28 |
| Ilustración 4: Tablas Silver - Elaboración Propia .....                                       | 30 |
| Ilustración 5: Diagrama DRH - Elaboración Propia.....                                         | 32 |
| Ilustración 6: Data Warehouse - Elaboración Propia .....                                      | 33 |
| Ilustración 7: Producción Mensual Tipo de Recurso - Elaboración Propia .....                  | 34 |
| Ilustración 8: Precio Mensual Tipo de Recurso - Elaboración Propia.....                       | 35 |
| Ilustración 9: Relación Producción vs Precio - Elaboración Propia .....                       | 36 |
| Ilustración 10: Matriz Correlación – Elaboración Propia.....                                  | 36 |
| Ilustración 11: Producción Total Mensual (Crudo) – Elaboración Propia .....                   | 37 |
| Ilustración 12: Producción Total Mensual - Media Móvil 12 Meses - Elaboración Propia .....    | 38 |
| Ilustración 13: Series y Componentes Producción Crudo - Elaboración Propia.....               | 39 |
| Ilustración 14: Producción Promedio Mes (Crudo) - Elaboración Propia .....                    | 40 |
| Ilustración 15: Autocorrelación Producción Crudo - Elaboración Propia .....                   | 41 |
| Ilustración 16: Parcial Autocorrelación Producción Crudo - Elaboración Propia.....            | 41 |
| Ilustración 17: Producción total mensual Gas - Elaboración Propia .....                       | 43 |
| Ilustración 18: Producción Total Mensual Gas - Media Movil 12 Meses - Elaboración Propia..... | 43 |
| Ilustración 19: Serie y Componentes Producción Gas - Elaboración Propia .....                 | 44 |
| Ilustración 20: Producción Promedio Mensual Gas - Elaboración Propia.....                     | 46 |
| Ilustración 21: Autocorrelación Producción Gas - Elaboración Propia .....                     | 46 |
| Ilustración 22: Parcial Autocorrelación Producción Gas - Elaboración Propia.....              | 47 |
| Ilustración 23: Distribución de Precios: Crudo vs Gas - Elaboración Propia .....              | 50 |
| Ilustración 24: Relación Entre Precios de Crudo y Gas - Elaboración Propia .....              | 51 |
| Ilustración 25: Precio promedio precios (Crudo y Gas) - Elaboración Propia .....              | 52 |
| Ilustración 26: Retornos Mensuales - Elaboración Propia .....                                 | 53 |
| Ilustración 27: Resultados Modelo Prophet (Crudo) - Elaboración Propia .....                  | 57 |
| Ilustración 28: Resultados Modelo SARIMA (Crudo) - Elaboración Propia .....                   | 58 |
| Ilustración 29: Resultados Modelo XGBOOST (Crudo) - Elaboración Propia .....                  | 58 |
| Ilustración 30: Resultados Modelo Prophet (Gas) - Elaboración Propia.....                     | 61 |

---

|                                                                                                |    |
|------------------------------------------------------------------------------------------------|----|
| Ilustración 31: Resultados Modelo SARIMA (Gas) - Elaboración Propia .....                      | 62 |
| Ilustración 32: Resultados Modelo XGBOOST (Crudo) - Elaboración Propia .....                   | 62 |
| Ilustración 33: Predicciones Prophet (Precios) - Elaboración Propia .....                      | 65 |
| Ilustración 34: Correlación Precios Train-Test - Elaboración Propia .....                      | 66 |
| Ilustración 35: Resultados Modelo XGBOOST (Precio Crudo) - Elaboración Propia .....            | 67 |
| Ilustración 36: Resultados Modelo LSTM – GRU (Precio Crudo) - Elaboración Propia .....         | 68 |
| Ilustración 37: Resultados Modelo XGBOOST (Precio Gas) - Elaboración Propia .....              | 69 |
| Ilustración 38: Resultados Modelo LSTM – GRU (Precio Gas) - Elaboración Propia .....           | 70 |
| Ilustración 39: Importancia Features (Producción Crudo) – Elaboración Propia .....             | 72 |
| Ilustración 40: SHAP valúes (Producción Crudo) - Elaboración Propia .....                      | 73 |
| Ilustración 41: Importancia Features (Producción Gas) – Elaboración Propia .....               | 75 |
| Ilustración 42: SHAP valúe (Producción Gas) - Elaboración Propia .....                         | 75 |
| Ilustración 43: Importancia Features (Precio Crudo) – Elaboración Propia .....                 | 77 |
| Ilustración 44: SHAP valúes (Precio Crudo) - Elaboración Propia .....                          | 78 |
| Ilustración 45: Importancia Features (Precio Gas) - Elaboración Propia .....                   | 79 |
| Ilustración 46: SHAP Values (Precio Gas) - Elaboración Propia .....                            | 80 |
| Ilustración 47: Predicción Producción Crudo - Elaboración Propia .....                         | 83 |
| Ilustración 48: Predicción Producción Gas - Elaboración Propia .....                           | 84 |
| Ilustración 49: Predicciones Precio Crudo - Elaboración Propia .....                           | 86 |
| Ilustración 50: Predicciones Precio Gas - Elaboración Propia .....                             | 87 |
| Ilustración 51: Dashboard Ilustrativo - Elaboración Propia .....                               | 88 |
| Ilustración 52: Escenario Precios Crudo - Elaboración Propia .....                             | 90 |
| Ilustración 53: Escenarios Precio Gas - Elaboración Propia .....                               | 90 |
| Ilustración 54: Escenarios Producción Crudo - Elaboración Propia .....                         | 91 |
| Ilustración 55: Escenario Producción Gas - Elaboración Propia .....                            | 91 |
| Ilustración 56: Sensibilidad Económica Precio vs Producción (Crudo) - Elaboración Propia ..... | 94 |
| Ilustración 57: Sensibilidad Económica Precio vs Producción (Gas) - Elaboración Propia .....   | 96 |

## Índice de Tablas

|                                                             |    |
|-------------------------------------------------------------|----|
| Tabla 1: Resultados Predicción Crudo.....                   | 71 |
| Tabla 2: Resultados Predicción Gas.....                     | 74 |
| Tabla 3: Resultados Predicción Precio Crudo.....            | 76 |
| Tabla 4: Resultados Predicción Precios Gas .....            | 79 |
| Tabla 5: Resultados Predicción Crudo - 12 meses.....        | 83 |
| Tabla 6: Resultados Predicción Gas - 12 meses .....         | 85 |
| Tabla 7: Resultados Predicción Precio Crudo - 12 meses..... | 86 |
| Tabla 8: Resultados Predicción Precio Gas - 12 meses .....  | 87 |
| Tabla 9: Resultados Escenarios Crudo.....                   | 92 |
| Tabla 10: Resultados Escenarios Gas .....                   | 95 |

## Capítulo 1. INTRODUCCIÓN

El sector energético constituye uno de los pilares fundamentales en la economía colombiana, representando una fuente significativa de ingresos, inversión extranjera y empleo, el petróleo y el gas natural no solo son principales productos de exportación del país, sino que también desempeñan un papel crucial en la seguridad energética nacional y en la financiación de programas sociales a través de regalías y los impuestos. En este sentido, la capacidad de anticipar el comportamiento futuro de la producción y los precios de estos commodities se convierte en una herramienta estratégica de importancia para la toma de decisiones en el ámbito público y privado.

La producción de hidrocarburos en Colombia enfrenta desafíos significativos derivados de factores geológicos, técnicos, regulatorios y de mercado. El declive natural de los campos maduros, la necesidad de nuevas inversiones en exploración, las restricciones ambientales y sociales, y la volatilidad de los precios internacionales crean un entorno de alta incertidumbre. Al mismo tiempo los precios internacionales de los commodities están sujetos a dinámicas globales complejas que incluyen decisiones, conflictos geopolíticos, avances tecnológicos en energías alternativas y shocks económicos como el provocado por la pandemia del COVID-19 que en abril llevó el precio del crudo a mínimos históricos de 18.38 USD por barril.

Tradicionalmente, la predicción de variables energéticas se ha abordado mediante modelos estadísticos y sus variantes estacionales, sin embargo, la creciente complejidad y volatilidad de los mercados, junto con la disponibilidad de mayores volúmenes de datos, han demostrado la necesidad a técnicas de Machine Learning y Deep Learning, capturando las relaciones no lineales y dependencias temporales complejas que los modelos tradicionales no pueden representar adecuadamente.

El presente trabajo de investigación tiene como objetivo principal desarrollar y comparar múltiples enfoques predictivos para la producción y los precios de crudo y gas en Colombia, utilizando datos históricos del periodo 2014-2025 proveniente de la Agencia Nacional de Hidrocarburos (ANH) y de la Reserva Federal de Estados Unidos

(FRED). Para ello, se implementó una arquitectura de datos moderna en Amazon Web Services (AWS) siguiendo una arquitectura medallion (Capas Bronze, Silver y Gold), que garantiza la calidad, trazabilidad y disponibilidad de la información para su consumo .

La metodología propuesta se da por fases, iniciando con la construcción de un Data Lakehouse en AWS, seguido de un análisis exploratorio profundo para comprender las características, patrones y relaciones de las series temporales, la implementación de modelos estadísticos, Machine Learning, seguido de la evaluación comparativo mediante métricas objetivas y la selección del modelo óptimo para cada variable objetivo.

Los resultados obtenidos confirman primero la baja correlación entre producción y precios, justificando su modelización independientemente, en cuanto a los precios de los commodities si tiene una correlación pequeña, pero que genera problema al momento de dividir la data para el uso de los modelos debido a su pequeña correlación.

En términos predictivos, los resultados demuestran la superioridad de modelos de Machine Learning en todos los casos de estudio, superando ampliamente a modelos estadísticos y de Deep Learning, el modelo seleccionado para producción de gas cuenta con los mejores números a nivel de métricas de evaluación para este tipo de proyectos que trabajan con series temporales, mostrando que los valores sirven de referencia para futuras investigaciones del sector.

## Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE

Este capítulo tiene como propósito ver las iniciativas y soluciones existentes en la industria energética que, al igual que este proyecto, emplean arquitectura de datos modernas en la nube y usan técnicas de Machine Learning para la optimización de procesos y la toma de decisiones. El propósito de estos antecedentes permite dar un contexto sólido sobre la propuesta de este proyecto, demostrando así las tendencias actuales del sector energético y poder justificar las decisiones tecnológicas adoptadas.

Tecnologías como la nube, Big Data y la Inteligencia Artificial están transformando todas las industrias, una que últimamente ha tomado fuerza en este campo en el sector energético, las empresas sin importar el tamaño están migrando desde enfoques tradicionales, a menudo basados en hojas de cálculo y procesos manuales, hacia plataformas analíticas y escalables. Estas nuevas arquitecturas permiten no solo el almacenamiento y procesamiento de grandes volúmenes de datos históricos e incluso en tiempo real, sino también la implementación de modelos predictivos para la optimización de activos, la predicción de precios, y la gestión de riesgos.

Analizaremos varios casos de estudios y soluciones desarrolladas por el sector energético que adoptaron este tipo de tecnologías.

### 2.1 Predicción de precios y optimización de Trading

La compañía energética **global bp**, desarrollo una solución sobre AWS para mejorar la captura de precios en sus operaciones de trading de materias primas<sup>1</sup>. El proyecto se enfocó en extraer información valiosa de conversaciones no estructurada entre traders y brokers, las cuales contienen cotizaciones de precios que no quedan registradas en los sistemas transaccionales. El proyecto abordó servicios serverless de AWS (Lambda, Step Functions) y modelos de Machine Learning alojados en Amazon SageMaker, permitiendo capturar datos de transacciones en tiempo real, enriquecer sus modelos de precios y mejorar la precisión de sus estrategias de trading. Este caso es

---

<sup>1</sup> Amazon Web Services. (2023, December 11). Enhance price capture in energy and commodity trading with AWS.



similar a la que se planteó en este proyecto, aunque no tratamos con datos en tiempo real, la ingesta también se basa en un servicio Serverless de AWS, demostrando la importancia de capturar y procesar información de fuentes diversas.

Otro ejemplo de este tipo de arquitecturas en de la empresa **Kinect Energy**, colaboro con Amazon ML Solution Lab para automatizar y mejorar la precisión de sus pronósticos de precios energéticos<sup>2</sup>, esta arquitectura implemento un pipeline completo con AWS, desde el momento es que se capturan los datos históricos de precios y tasas de producción, hasta la generación de pronósticos con el algoritmo DeepAR de SageMaker, este es un ejemplo clave que da fuerza a este proyecto no solamente para el uso de arquitectura Serverless, sino también para implementar algoritmos de forecasting de Deep Learning para predecir series temporales en el sector energético, en el cual también se centra este proyecto TFM.

## 2.2 Optimización y estrategia

Una empresa consultora llamada **iCAT**, en colaboración con Clouadar, implemento una plataforma de pronóstico de precios energéticos para uno de sus clientes.<sup>3</sup> La solución destaca debido a sus modelos para proporcionar explicabilidad y análisis de tendencias en lenguaje natural, haciendo que los resultados sean accesibles para las personas que tenían que tomar decisiones, también se reportó que debido a esto el tiempo de procesamiento bajo en un 50% y sus costos estimaron un ahorro de un 30%.

## 2.3 Plataforma de datos para decisiones Upstream

Para el ámbito Upstream (Exploración y Producción), **S&P Global Commodity Insights** junto con AWS crearon una solución para el análisis de refinerías.<sup>4</sup> La plataforma que se ejecuta en la nube de AWS, permite ejecutar escenarios de optimización de refino, bajo los tiempos de computación, lo

---

<sup>2</sup> Amazon Web Services. (2019, August 7). *Kinect Energy uses Amazon SageMaker to Forecast energy prices with Machine Learning*

<sup>3</sup> Clouadar. (2024, September 16). *iCAT - Precision Energy Price Forecasting*.

<sup>4</sup> AspenTech. (2025, February 19). *S&P Global Commodity Insights Creates Sustainable Value for the Oil Industry*.

importante de este desarrollo es que la herramienta permite a analistas con menos experiencia realizar análisis complejos y a traders o bancos de inversión acceder a modelos rigurosos del mercado de refino. La empresa estableció un acuerdo con AWS para poner a disposición de la industria, a través de AWS Data Exchange, un catálogo masivo de datos upstream, permitiendo la creación de data lakes abiertos y accesibles que separan los datos de las aplicaciones, un principio fundamental de la arquitectura medallón y el Data Lake en S3 implementados en este proyecto.

## 2.4 Servicios de AWS para análisis de Commodities

Servicios como **Amazon S3**, **Amazon Athena**, **Amazon Glue (o DBT)** se han convertido en un patrón de arquitectura de referencia para proyectos de analítica de Commodities y energía, así lo demuestra de portafolio llamado *"insightflow-retail-economic-pipeline"*.<sup>5</sup> Aunque es usado en un ámbito comercial al igual que este proyecto usa las mismas tecnologías (S3, Athena, dbt) para analizar correlaciones entre la producción y los precios.

Los antecedentes presentados demuestran que la industria energética está adoptando de manera decidida las arquitecturas Cloud y Machine Learning para resolver desafíos críticos de optimización y predicción, el presente proyecto de este TFM se enmarca dentro de esta misma línea de soluciones, adoptando tecnologías al contexto específico de la producción de petróleo y gas en Colombia, y su relación con los precios internacionales.

---

<sup>5</sup> gps31320779. (2024). *insightflow-retail-economic-pipeline* [Portfolio project].

## Capítulo 3. OBJETIVOS

Este capítulo tiene como propósito establecer los objetivos generales y específicos del Trabajo de Fin de Master, en el cual se enfocara en el estudio predictivo de producciones de petróleo y gas, y sus aplicaciones en el precio, se evaluara partiendo de la información publicada por la entidad regulatoria de producción de Colombia Agencia Nacional de Hidrocarburos (ANH) del periodo del año 2014 al 2025, y los datos de precio promedio mensual del portal Federal Reserve Bank of ST. LOUIS (BRENT y DHHNGSP).

### 3.1 Objetivo general

El objetivo general de este Trabajo de Fin de Máster es desarrollar, comparar y evaluar modelos predictivos que nos ayuden a predecir la producción de petróleo y gas, y sus aplicaciones en determinación de precios de commodities utilizando modelos de predicción.

Este objetivo no solo tratara de la parte de desarrollo de los modelos, sino también en la parte de diseñar, implementar y validar una plataforma integral de análisis predictivo orientado al sector energético, capaz de estimar la producción futura de petróleo y gas, analizar su impacto en la dinámica de precios, mediante la construcción de una arquitectura de datos end-to-end basadas en tecnologías cloud.

Se contempla el desarrollo de un pipeline completo de ingeniería de datos que incluye la ingesta de datos, su procesamiento mediante una arquitectura tipo Medallion (Bronze, Silver y Gold) la modelación de un Data Warehouse analítico, y la posterior aplicación de modelos predictivos con el fin de evaluar su desempeño, robustez, y capacidad de generalización en escenarios reales.

Asimismo, se busca integrar los resultados en herramientas de visualización y análisis para facilitar la toma de decisiones estratégicas, demostrando la viabilidad de una solución tecnológica escalable y reproducible para la predicción de variables clave en la industria de hidrocarburos.

## 3.2 Objetivos específicos

El objetivo general se desglosa en varios objetivos específicos, los cuales permiten el desarrollo del proyecto, cada uno de ellos responde a una fase importante del proceso: creación de la arquitectura, recopilación de datos, preparación de datos, análisis de datos, modelado, evaluación e interpretación de los resultados.

- **Extracción de datos:** Identificar y recopilar los datos relevantes sobre la producción de petróleo y gas del portal de datos abiertos de la Agencia Nacional de Hidrocarburos (ANH), así como la de precio internacional de petróleo y gas del portal Federal Reserve Back of ST. LOUIS (FRED).
- **Diseño de arquitectura:** Diseñar e implementar una arquitectura de datos escalable en la nube, basada en un Data Lake y estructura bajo el enfoque de una arquitectura medallón, que permita la ingestión, almacenamiento y organización eficiente de los datos.
- **Proceso ETL/ELT:** Desarrollar procesos de ingeniería de datos (ETL/ELT) para la limpieza, transformación y enriquecimiento de los datos, asegurando que los datos estén adecuados para análisis adecuados y modelos predictivos.
- **Data Warehouse:** Construir un Data Warehouse analítico que consolide la información procesada en un modelo estructurado para la toma de decisiones, facilitando consultas eficientes y análisis histórico.
- **Modelado de datos:** Implementar herramientas de transformación y modelado de datos para estandarizar y automatizar los procesos de preparación de la información dentro de la arquitectura propuesta.
- **Análisis de datos:** Realizar un análisis exploratorio (EDA) para identificar tendencias, estacionalidades, patrones o posibles rupturas estructurales en la producción de hidrocarburos.
- **Modelos predictivos:** Desarrollar y aplicar modelos predictivos de series temporales basados en Machine Learning para estimar la producción futura de petróleo y gas.
- **Comparación de modelos:** Comparar el desempeño de los diferentes modelos predictivos, utilizando métricas cuantitativas apropiadas (MAE, MAPE,  $R^2$ , entre otras), con el propósito de determinar el modelo más adecuado para el desarrollo del proyecto.


- 
- **Análisis producción, precios:** Analizar la relación entre la producción de hidrocarburos y la evolución de los precios de commodities energéticos, evaluando posibles implicaciones económicas y operativas.
  - **Visualización de datos:** Integrar los resultados en herramientas de visualización de datos, facilitando la interpretación de los pronósticos y el apoyo a la toma de decisiones mediante dashboards analíticos.

## Capítulo 4. METODOLOGÍA

### 4.1 Metodología del proyecto

Para la implementación de este TFM en la solución end-to-end donde integramos ingeniería de datos con modelado predictivo, el proyecto se estructuró siguiendo una metodología por fases, cada fase se centra en un conjunto de actividades específicas y cuenta con entregables bien definidos, garantizando trazabilidad y calidad a la entrega final, el enfoque permite ajustes y mejoras a medida que se va avanzando en el proyecto.

El diagrama siguiente ilustra el flujo de trabajo de la metodología propuesta.



*Ilustración 1: Metodología – Elaboración Propia*

A continuación, se detalla cada una de las fases.

#### 4.1.1 Fase 1: Definición del Proyecto y análisis

Esta es una de las fases fundamentales en todos los proyectos para establecer la base de lo que se desea lograr, no se trata solo saber con qué data se cuenta, si no de entender que preguntas se quiere responder, esta fase se compone de las siguientes actividades:

- **Definición de Objetivos:** Se especificaron, objetivo general y objetivos específicos ya planteados anteriormente.
- **Identificación de fuentes de datos:** Se confirmo las fuentes de los portales de la ANH (Producción) y FRED (precios Brent y Henry Hub), analizando la estructura, periodicidad y volumen de datos.
- **Diseño lógico del DWH:** Definir el modelo estrella de acuerdo con la estructura de los datos adquiridos de los portales.
- **Alcance de los modelos predictivos:** Definir las series temporales para los modelos y explorar la relación entre las variables a predecir.

#### 4.1.2 Fase 2: Diseño e implementación de la arquitectura de datos

En esta fase se construye la tubería (pipeline) por la que se estarán moviendo los datos, implementando la arquitectura sobre AWS, las actividades a realizar son las siguientes:

- **Configuración del Data Lake en S3:** Creación de Buckets y estructura de carpetas para las capas Bronze, Silver y Gold, configuración de los versionados.
- **Capa Bronze (Ingesta):** Se cargará los archivos bajados de las fuentes originales sin ningún tipo de modificación, esto sirve para temas de auditoria en el futuro.
- **Capa Silver (Transformación y limpieza):** Uso de dbt para modelar las transformaciones, desde DBT se conectará a los datos que están en bronce, ejecutando limpieza, estandarización, el resultado se guardara en la capa silver.
- **Capa Gold (Modelo dimensional):** Construcción de modelo estrella, tomando de silver las tablas limpias, creando tablas de dimensiones y hechos, el resultado se guardará en la capa Gold en formato parquet.

#### 4.1.3 Fase 3: Análisis exploratorio EDA:

Una vez los datos están limpios y estructurados en Athena, se procederá a explorarlos para entender sus características y validar hipótesis iniciales, este análisis se realizará a través del lenguaje de

Python y sus librerías de análisis, cargando los datos en un notebook de Jupyter a través de un conector de Athena, las actividades serán:

- **Conexión y consulta:** Uso de librerías para cargar las tablas de Hechos del DWH.
- **Análisis univariante:** Visualización de la evolución temporal de cada serie, identificar tendencias, estacionalidad, picos y valores atípicos.
- **Análisis multivariante:** Exploración de la relación de las variables, análisis de la producción por departamento, operadora o tipo de contrato.
- **Identificación de modelos:** Con base al EDA, se determinarán las características más relevantes que podrían alimentar los modelo.

#### 4.1.4 Fase 4: Modelo predictivo

Con el conocimiento adquirido en el EDA, se procede a la implementación y evaluación de los modelos, dividiendo las tareas de la siguiente manera:

- **Preparación de los datos:** Creación de conjuntos de datos para los modelos, esto implica extraer las series temporales de las tablas Gold, crear variables de calendario para capturar estacionalidad, crear variables rezagadas de la propia serie y de variables exógenas y finalmente dividir los datos en conjunto de entrenamiento y test.
- **Implementación de modelos:** Se implementarán diferentes modelos para comparar su rendimiento.
- **Entrenamiento y validación:** Entrenamiento de los modelos con el conjunto de entrenamiento, uso de técnicas para ajustar hiperparametros y evitar sobreajustes.
- **Evaluación de resultados:** Evaluación del rendimiento de los modelos entrenados sobre los conjuntos de prueba, utilizando métricas como MAE, MAPE,  $R^2$ .

#### 4.1.5 Fase 5. Análisis de resultados y visualización

La última fase se centra en interpretar los resultados de los modelos y comunicarlos de manera efectiva, esta fase se basa en las siguientes actividades.



- **Visualización Power BI:** Conectar power BI con Athena, crear un dashboard interactivo que muestre la evolución histórica de la producción y precios, los resultados EDA, una sección dedicada a los pronósticos donde se muestren las predicciones con los modelos con datos reales.

## **CAPITULO 5. DESARROLLO E IMPLEMENTACIÓN**

### **5.1 Introducción al desarrollo**

El presente capítulo tiene como propósito describir el proceso de diseño, implementación y validación de la solución propuesta para la predicción de petróleo y gas, así como su relación con los precios de commodities energéticos. Este capítulo trata del desarrollo práctico de una solución end-to-end, desde el momento en que se quieren los datos, hasta la generación de los modelos predictivos y su visualización para la toma de decisiones.

La implementación se basa en una ingeniería de datos moderna, desplegada sobre una arquitectura Cloud escalable en AWS. Esta arquitectura permite gestionar datos históricos proveniente de fuentes como la ANH y la plataforma FRED, garantizando su disponibilidad, calidad y consistencia a lo largo de todo el ciclo de vida del dato, todas las fases del proyecto han sido desarrolladas de manera íntegra, asegurando la trazabilidad y reproducibilidad de los resultados.

A lo largo de este documento, se detallará la implementación concreta de cada una de las fases, se mostrará la manera en que se ingestaron y transformaron los datos, se mostrarán los análisis exploratorios y el entrenamiento de modelos, así como la captura del dashboard final en Power BI, así de esta manera no solo se documenta el trabajo realizado, sino que se proporciona una guía reproducible para futuros proyectos similares en el sector energético.

Por último, se mostrará la evaluación de los modelos predictivos desarrollados, se comparará su rendimiento mediante métricas estandarizadas y se analizará la relación entre variables de producción y precio, ofreciendo así una base tecnológica y analítica sólida para la planificación estratégica en el sector.

### **5.2 Implementación de la Arquitectura de Datos en AWS**

Para el desarrollo del proyecto, se implementó una arquitectura de Datos robusta y escalable en Amazon Web Services (AWS), siguiendo los principios de un moderno Lakehouse que combina la

flexibilidad de una Data Lake, además la estructuración de un Data Warehouse, la arquitectura diseñada permite el flujo eficiente de datos desde las fuentes originales hasta su consumo en modelos predictivos y visualizaciones, garantizando la calidad, la trazabilidad y disponibilidad de la información.

A continuación, se muestra un gráfico de la arquitectura empleada y el pipeline de datos.




Ilustración 2: Arquitectura AWS – Elaboración Propia

### 5.2.1. Configuración del Data Lake

El punto de partida del proyecto en la parte técnica en la creación y configuración del Data Lake en Amazon S3, siguiendo los principios de la arquitectura medallion definidos en la metodología, el servicio de S3 fue elegido capa de almacenamiento fundamental por su escalabilidad, durabilidad y su capacidad para integrarse de manera nativa con el resto de los servicios del ecosistema AWS<sup>6</sup>


Para mantener una separación lógica y física de los datos en los diferentes niveles de procesamiento, se optó por crear tres carpetas independientes, uno por cada capa de la arquitectura medallion, esta decisión permite aplicar políticas de seguridad, ciclo de vida y control de accesos diferenciadas por capa, siguiendo las recomendaciones de mejores prácticas de AWS.<sup>7</sup>

<sup>6</sup> DEV (December 2025). Medallion Architecture on AWS.

<sup>7</sup> DEV (December 2025). Medallion Architecture on AWS.

### Estructura de Bucket creada:

Dentro de cada carpeta, se definió una estructura de subcarpetas que organiza los datos por tipo de contenido, facilitando la navegación y el particionamiento futuro.



*Ilustración 3: Estructura Data Lake - Elaboración Propia*

En cuanto a la configuración de seguridad y gobernanza, se aplicaron las siguientes políticas:

- **Cifrado:** Se habilitó el cifrado del lado del servidor (SSE-S3) por defecto en los tres Buckets para garantizar la protección de los datos en reposo, siguiendo el principio de seguridad por defecto.
- **Control de accesos:** Se configuraron políticas del Bucket específicos para cada capa, limitando el acceso de escritura únicamente a los servicios autorizados.
- **Versionado:** Se activó el versionado en el Bucket para mantener un histórico de todas las versiones de los archivos crudos, permitiendo auditoría y reprocesamiento en caso de errores o sobreescrituras accidentales.

Esta separación por capas no solo mejora la gobernanza, sino que también facilita la implementación de políticas de retención y seguridad por nivel en los datos.

### 5.2.2. Ingesta de Datos a la capa Bronze

Una vez que se configura la infraestructura de almacenamiento en S3, el siguiente paso consistió en cargar los datos históricos de producción y precios en la capa Bronze.

#### Fuentes de datos:

- **Producción:** Archivos CSV descargados del portal de datos abiertos de la Agencia Nacional de Hidrocarburos (ANH), correspondiente al periodo de enero de 2024 – agosto de 2025.
- **Precios:** Archivos CSV obtenidos del portal FRED (Federal Reserve Bank of St. Louis), correspondientes al precio mensual del petróleo BRENT y del gas Henry Hub para el mismo periodo.

#### Justificación del enfoque:

Mantener los datos originales inalterados en la capa Bronze responde a dos principios fundamentales de la arquitectura:

- **Inmutabilidad:** Los datos crudos nunca deben modificarse, esto permite reprocesar desde el origen en caso de que se detecten errores en las capas superiores.
- **Auditoria:** La capa Bronze permite auditar que datos fueron recibidos originalmente, en qué formato y en qué momento.

### 5.2.3 Transformaciones a la capa Silver

Una vez los datos crudos fueron almacenados en Bronze, el siguiente paso consistió en su transformación y limpieza para obtener un conjunto de datos estandarizado y listo para el análisis, para esta tarea se utilizó consultas SQL, un lenguaje que permite transformar datos.

#### Transformaciones a Silver – Producción:

- **Estandarización de fechas:** Conversión a formato DATE uniforme.
- **Limpieza de textos:** Eliminación de espacios en blanco, conversión a mayúsculas para


campos categóricos.

- **Manejo de nulos:** Sustitución de valores nulos en producción por 0.
- **Estandarización de unidades:** Unificación de criterios para “barriles” y “mcf”.

#### transformaciones a Silver – Precios:

- **Estandarización de fechas:** Conversión a formato DATE uniforme.
- **Estandarización de unidades:** Unificación de criterios para “BARRIL” y “MMBTU”.

Tras la ejecución, los datos los datos quedaron en dos tablas en la capa Silver, almacenados de la siguiente manera



*Ilustración 4: Tablas Silver - Elaboración Propia*

Al crear las tablas, los datos también fueron almacenados en formato parquet en la ubicación de la capa silver del S3. El uso del formato Parquet nos ayuda en gran manera en el rendimiento de las consultas respecto al CSV original, también se reduce el espacio en un 70% y mejora la velocidad de lectura en Athena.

#### 5.2.4 Construcción de modelo dimensional

Una vez los datos se encuentran limpios y estandarizados en la capa Silver, el siguiente paso consistió en su transformación a un **modelo dimensional en estrella** en la capa Gold, este modelo constituye

la base del Data Warehouse analítico, permitiendo que pueda ser consultado por el negocio, dashboards y usados para modelos predictivos.

Siguiendo las mejores prácticas del modelo dimensional (Kimball, 2013),<sup>8</sup> se identificaron las siguiente dimensiones y tablas de hechos:

#### **Dimensiones:**

- **dim\_campo:** Campos petroleros productores
- **dim\_operadora:** Empresas operadoras con contratos
- **dim\_recurso:** Tipo de recurso (Crudo o Gas) y sus unidades
- **dim\_tiempo:** Calendario con atributos como año, mes, etc.
- **dim\_ubicacion:** Departamentos y municipios de Colombia.

#### **Tablas de hechos**

- **fact\_producción:** Hechos de producción mensual a nivel de campo
- **fact\_precio\_mensual:** Hechos de precios mensuales de commodities.

#### **Implementación en dbt**

Se crearon modelos independientes para cada dimensión y cada hecho dentro del proyecto dbt, siguiendo la misma estructura ya planteada, a continuación, se muestra el esquema del modelo estrella.

La elección del modelo estrella permite:


- Rendimiento en consultas
- Entendimiento para usuarios del negocio

---

<sup>8</sup> Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit*

### 5.2.5 Implementación del Data Warehouse

Una vez que los datos fueron modelados y almacenados en la capa GOLD con formato parquet, el siguiente paso consistió en hacerlos accesibles para consultas analítica mediante AWS Athena, un motor de consultas serverless que permite ejecutar SQL directamente sobre los datos almacenados en S3.



*Ilustración 5: Diagrama DRH - Elaboración Propia*

Athena fue seleccionado como motor del Data Warehouse por las siguientes razones:

- Al ser serverless no requiere aprovisionamiento, ni gestión de infraestructura, permitiendo reducción de costos.
- Trabaja directamente sobre los archivos Parquet en S3, eliminando la necesidad de movimientos de datos adicionales.
- Solo se factura por los datos escaneados, lo que resulta económico para cargas de trabajo analíticas.
- Permite usar SQL sin necesidad de aprender otros lenguajes o herramientas.


Para que Athena pueda interpretar la estructura de los datos almacenados en S3, es necesario definir un catálogo de **metadatos**, AWS proporciona **AWS Glue Catalog** como un repositorio centralizado de



metadatos compatible con Athena. El proceso de configuración consistió en:

- Crear una base de datos en Glue Catalog que agrupa todas las tablas del Data Warehouse.
- Registro de las tablas externas para cada una de las tablas Gold generadas por DBT

Una vez configurado el catálogo y cargadas las particiones, se procedió a verificar el correcto funcionamiento del Data Warehouse a través de consultas de prueba.



The screenshot shows the Amazon Athena console interface. On the left, the 'Datos' (Data) sidebar is visible, showing the 'Origen de datos' (Data source) as 'AwsDataCatalog', the 'Catálogo' (Catalog) as 'Ningún elemento' (No element), and the 'Base de datos' (Database) as 'gold\_produccion'. Below this, the 'Tablas y vistas' (Tables and views) section lists several tables: 'dim\_campo', 'dim\_operadora', 'dim\_recurso', 'dim\_tiempo', 'dim\_ubicacion', 'factPrecioMensual', and 'factProduccion'. The main area displays a SQL query for 'Consulta 7' and its results. The query is a SELECT statement joining 'gold\_produccion' and 'factProduccion' on 'fecha' and 'tipo\_recurso'. The results table shows 10 rows of data with columns: '#', 'fecha', 'tipo\_recurso', 'produccion\_total', and 'precio\_promedio'.

| #  | fecha                   | tipo_recurso | produccion_total | precio_promedio |
|----|-------------------------|--------------|------------------|-----------------|
| 1  | 2016-07-01 00:00:00.000 | crudo        | 35.0             | 44.95           |
| 2  | 2016-08-01 00:00:00.000 | crudo        | 29455.0          | 45.84           |
| 3  | 2014-09-01 00:00:00.000 | crudo        | 48282.0          | 97.09           |
| 4  | 2018-04-01 00:00:00.000 | crudo        | 78822.83         | 72.11           |
| 5  | 2015-03-01 00:00:00.000 | crudo        | 155685.0         | 55.89           |
| 6  | 2017-04-01 00:00:00.000 | crudo        | 1548.0           | 52.31           |
| 7  | 2014-06-01 00:00:00.000 | crudo        | 19092.0          | 111.8           |
| 8  | 2019-07-01 00:00:00.000 | crudo        | 7726.0           | 63.92           |
| 9  | 2018-11-01 00:00:00.000 | crudo        | 3262.4           | 64.75           |
| 10 | 2018-01-01 00:00:00.000 | crudo        | 11007.63         | 69.08           |

*Ilustración 6: Data Warehouse - Elaboración Propia*

## 5.2.6 Resumen de la implementación

En resumen, la implementación de la arquitectura permitió:

- **Centralizar metadatos:** Facilitando la gobernanza de datos a través de AWS Glue Catalog.
- **Acceder a los datos Gold:** A través de consultas SQL estándar, sin necesidad de moverlos de S3.
- **Reducción de costos:** A través de las técnicas utilizadas (Archivos Parquet) se reduce costos y se optimizan tiempos de respuesta.

Con esta fase operativa, los datos quedaron listos para las siguientes fases del proyecto.


## 5.3 Análisis Exploratorio de Datos (EDA)

Este análisis tiene como objetivo mostrar el comportamiento histórico de la producción en Colombia y los precios de los hidrocarburos internacionales, ayudándonos a identificar patrones y estacionalidad, también nos ayuda a establecer las bases para la selección y construcción de los modelos predictivos.

### 5.3.1 Carga y análisis inicial


Se cargaron dos conjuntos de datos principales desde el Data Warehouse en AWS Athena:

- **fact\_produccion:** Contiene el registro mensual de producción de petróleo (crudo) y gas por campo, operadora y ubicación geográfica.



*Ilustración 7: Producción Mensual Tipo de Recurso - Elaboración Propia*

- **fact\_precio\_mensual:** Contiene el precio promedio mensual en dólares (USD) por barril de crudo y por unidad de gas.



*Ilustración 8: Precio Mensual Tipo de Recurso - Elaboración Propia*

Un primer análisis mostro la integridad de los datos, el dataframe de producción consta de **115,576 registros**, las fechas abarcan desde enero de 2014 hasta septiembre de 2025. Por su parte, el dataframe de precios contiene **288 registros**, con un rango de fechas similar, desde enero de 2014 a diciembre de 2025.

### 5.3.2 Análisis de relación entre Producción y Precio

Como paso inicial, se exploró la posible relación entre la producción total mensual y el precio promedio mensual. Se consolido la información en un único dataframe para sus análisis.

Se utilizo un gráfico de dispersión para ver la producción total versus el precio promedio para visualizar cualquier tendencia conjunta.




Ilustración 9: Relación Producción vs Precio - Elaboración Propia

De igual manera se creó una **matriz de correlación**.




Ilustración 10: Matriz Correlación – Elaboración Propia


El resultado de este análisis nos indica que la correlación entre producción y precio es extremadamente baja, esto nos indica que es fundamental **crear modelos de predicción para crudo y para gas de forma independiente**, utilizando únicamente sus valores históricos como base para la predicción, sin incluir el precio como variable exógena.

### 5.3.3 Análisis de evolución de la Producción de Petróleo (Crudo)

Para un análisis más detallado y enfocado en la predicción de crudo, se tuvo que crear un dataframe filtrado solamente por la producción de crudo y se consolidó a nivel mensual, teniendo ahora una sola serie temporal de crudo, fue conveniente que el dataframe fuera indexado por fecha y se le asignó una frecuencia mensual ('MS') para garantizar la regularidad de los datos.

Lo primero fue crear una gráfica de la producción total mensual de crudo en función del tiempo, esta gráfica permite observar el rango de los datos, la magnitud de las variaciones y la posible existencia de una tendencia general.

La gráfica muestra la evolución de la producción de crudo desde enero de 2014 hasta agosto de 2025. En ella se puede apreciar que la producción no es constante, se observan periodos de crecimiento, estabilización y descenso a lo largo de los años, lo que sugiere la presencia de una tendencia a largo plazo y descarta que la serie sea un proceso puramente aleatorio o ruido blanco, también se puede notar las fluctuaciones de un mes a otro, indicando una alta volatilidad a corto plazo.




*Ilustración 11: Producción Total Mensual (Crudo) – Elaboración Propia*

Para distinguir la dirección real, se aplicó una media móvil de 12 meses a la serie, esta técnica

estadística suaviza las funciones a corto plazo (incluyendo la estacionalidad anual) al promediar los datos de cada punto con los de los once meses anteriores, permitiendo que la dirección a largo plazo sea visible con mayor claridad.

La grafica representa el resultado, la línea muestra con mayor claridad la trayectoria de la producción al largo de los años, se observan periodos con cambios en la pendiente, lo que indica que el sistema productivo no sigue una dinámica estable y podría estar influenciado por factores estructurales como cambios económicos, regulatorios o de mercado. Esta tendencia cambiante es una característica clave de cualquier modelo predictivo debería considerar.



*Ilustración 12: Producción Total Mensual - Media Móvil 12 Meses - Elaboración Propia*

Para un diagnóstico más formal, se procedió a descomponer la serie temporal en sus componentes fundamentales mediante el método de descomposición aditiva, este método asume que la serie observada es la suma de una tendencia de largo plazo, un componente estacional que se repite cada año y un componente residual o “ruido” que no puede ser explicado por los dos anteriores.




*Ilustración 13: Series y Componentes Producción Crudo - Elaboración Propia*

- **Serie Observada:** Serie Original.
- **Componente de Tendencia:** Confirma de manera inequívoca la existencia de una evolución a largo plazo en la producción total, con cambios en su pendiente a lo largo del tiempo.
- **Componente Estacional:** Este grafico revela un patrón recurrente que se repite aproximadamente cada 12 meses, lo que indica la presencia de una estacionalidad anual. Aunque la magnitud de esta componente no es dominante en comparación con la tendencia, su persistencia en el tiempo justifica su inclusión explícita en los modelos de predicción.
- **Componente Residual:** Este grafico agrupa las fluctuaciones no explicadas por la tendencia ni la estacionalidad, su comportamiento debe parecerse idealmente a ruido blanco (sin patrones). La presencia de algunos picos podría estar asociada a eventos excepcionales, pero en general no muestra una estructura clara, lo que valida la calidad de la descomposición.

Para visualizar de manera más directa el comportamiento intra-anual de la producción, se calculó la producción promedio para cada mes del año a lo largo de todo el periodo en estudio.

La siguiente grafica nos muestra que ciertos meses (como los primeros) presentan niveles de producción consistentemente más altos que otros, esta diferencia sistemática entre los meses confirma la existencia de una **estacionalidad anual moderada** en la producción de crudo, un factor que los modelos predictivos deben considerar para realizar pronósticos precisos.




*Ilustración 14: Producción Promedio Mes (Crudo) - Elaboración Propia*

Por último, se analizó la dependencia temporal de la serie mediante las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF). La ACF mide la correlación de la serie consigo misma en diferentes rezagos (lags), mientras que la PACF mide la correlación en un rezago específico, eliminando la influencia de los rezagos intermedios.


Esta grafica presenta estas funciones para los primeros 36 rezagos (tres años), notando que la ACF decae lentamente, un comportamiento típico de series no estacionarias con tendencia. La PACF, por



otro lado, muestra algunos picos significativos en los primeros rezagos, especialmente en el lag1 y lag2.



*Ilustración 15: Autocorrelación Producción Crudo - Elaboración Propia*



*Ilustración 16: Parcial Autocorrelación Producción Crudo - Elaboración Propia*

Este resultado tiene una implicación directa para el modelado, indicándonos que los valores pasados de la producción (especialmente los más recientes) tienen un poder predictivo sobre los valores futuros. Esta característica, conocida como autocorrelación, hace que sea la serie adecuada para modelos autorregresivos, como los que se exploran en la sección de modelado.


Para confirmar formalmente la observación visual de una tendencia, se aplicó la prueba Dickey-Fuller aumentada (ADF), esta prueba tiene como hipótesis nula que la serie es no estacionaria. Un p-valor bajo (típicamente  $< 0.05$ ) permite rechazar la nula y concluir que la serie es estacionaria.

El resultado de la prueba arrojó un **p-valor de 0.1347**, dado que este valor es superior a 0.05, **no se puede rechazar la hipótesis nula**. Por lo tanto, se confirma estadísticamente que la serie de producción de crudo no es estacionaria, esta observación es fundamental ya que justifica la necesidad de aplicar transformaciones (como diferenciación) o emplear modelos que puedan manejar explícitamente tendencias y cambios estructurales en los datos, como con los modelos Prophet, SARIMA, LSTM o Skforecast.

#### 5.3.4 Análisis de evolución de la Producción Gas

Siguiendo el mismo proceso aplicado a la producción de crudo, se procedió a filtrar y consolidar la producción de gas en una sola serie temporal mensual, de la misma forma que con la serie temporal de crudo, la serie de la producción de gas fue indexada por fecha y se le asignó una frecuencia mensual ('MS') para garantizar la regularidad de los datos.


El primer paso fue graficar la producción total mensual de gas en función del tiempo, la siguiente gráfica muestra la evolución de la producción de gas desde enero de 2014 hasta agosto de 2025.



*Ilustración 17: Producción total mensual Gas - Elaboración Propia*

Podemos observar que la serie es muy diferente a la de crudo, la producción de gas presenta una variabilidad significativa y una tendencia decreciente mucho más pronunciada, se identifica periodos de alta producción, seguido de caídas abruptas, lo que sugiere que puede ser una dinámica de mercado y de extracción diferente a la del petróleo, influenciada por factores propios del sector gasífero.

Al igual que con el crudo, aplicamos una media móvil de 12 meses a la serie de gas, la gráfica muestra el resultado de este suavizado.



*Ilustración 18: Producción Total Mensual Gas - Media Movil 12 Meses - Elaboración Propia*

La línea de tendencia resultante confirma que la producción de gas sigue una trayectoria general descendente a lo largo del tiempo, se observan periodos de cierta estabilización o mesetas, seguidos

de nuevos descensos, la caída al final de la serie estaría mostrando un posible punto de quiebre estructural o un agotamiento en la producción, se debe tener claro que al ir bajando la tendencia indicaría que esta una característica dominante que cualquier modelo predictivo tendría que capturar.

También se realizó la descomposición de la serie temporal de gas utilizando el mismo método de descomposición aditiva como lo muestra la imagen, permitiendo un análisis detallado de cada componente.



*Ilustración 19: Serie y Componentes Producción Gas - Elaboración Propia*

- **Serie Observa:** Es la serie original de gas
- **Componente de Tendencia:** Este grafico confirma de manera contundente la evolución decreciente de largo plazo de la producción de gas, identificando periodos con variaciones

en la pendiente, indicando que el sistema productivo no sigue una trayectoria lineal y puede estar afectado por cambios económicos o regulatorios específicos del sector.

- **Componente Estacional:** El grafico revela un patrón recurrente con periodicidad anual, lo que sugiere la existencia de estacionalidad en la producción de gas, aunque en su magnitud es menor en comparación con la tendencia, su constancia en el tiempo justifica su consideración en los modelos de predicción.
- **Componente Residual:** En esta parte se agrupa las fluctuaciones no explicadas por la tendencia ni la estacionalidad, en el caso de gas se observa valores atípicos (outliers) de mayor magnitud que en el crudo, estos podrían estar asociados a eventos excepcionales, lo que indica que la producción de gas también esta influenciada por factores exógenos no periódicos que aumentan la incertidumbre del pronóstico.

Para visualizar de manera más directa el comportamiento intra-anual de la producción de gas, se calculó su producción promedio para cada mes del año.

La grafica muestra diferencias sistemáticas entre los meses del año, con ciertos meses presentando niveles de producción consistente mayores o menores, esto también nos confirma la presencia de una estacionalidad anual moderada en la producción de gas, un factor que, aunque de menor impacto que la tendencia, debe ser considerado en los modelos predictivos para mejorar su precisión.




Ilustración 20: Producción Promedio Mensual Gas - Elaboración Propia

Se analizo la dependencia temporal de la serie de gas mediante las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF), presentadas en las siguientes graficas.





Ilustración 21: Autocorrelación Producción Gas - Elaboración Propia



*Ilustración 22: Parcial Autocorrelación Producción Gas - Elaboración Propia*

Al igual que con Crudo, la ACF de la producción de gas muestra un decaimiento lento, esto sucede en las series no estacionarias con una fuerte tendencia. La PACF, por otro lado, muestra algunos picos significativos en los primeros rezagos (lags 1 y 2). Este resultado puede adoptar aspectos semejantes al del crudo, mostrando una fuerte dependencia temporal, indicando que los valores pasados de la producción de gas son predictores significativos de sus valores futuros.

Esta característica valida el uso de modelos autorregresivos, aunque la marcada no estacionariedad y la presencia de outliers podrían limitar el uso de modelos como ARIMA.

Finalmente, para confirmar la no estacionalidad de la serie, aplicamos la prueba de Dickey-Fuller aumentada (ADF). El resultado de la prueba arroja un **p-valor 0.9927**. Este valor corno a 1 es demasiado alto y muy superior al umbral de 0.05, por lo tanto, no se puede rechazar la hipótesis nula y se confirma de manera contundente que la serie de producción de gas no es estacionaria.

Esta observación era esperada, dada la fuerte tendencia decreciente observada, confirma la necesidad de aplicar transformaciones o de emplear modelos robustos que puedan manejar explícitamente tendencias complejas y cambios estructurales.

### 5.3.5 Conclusiones del Análisis Exploratorio

El análisis exploratorio de datos nos ha permitido ver en profundidad del comportamiento de la producción de hidrocarburos en Colombia, los hallazgos más relevantes se resumen a continuación, y de ellos se pueden tomar consideraciones claves para la selección de modelos predictivos que serán implementados en la siguiente fase del proyecto.

El primer hallazgo significativo fue la **no correlación entre la producción y el precio** de los hidrocarburos, la matriz de correlación arrojó un valor cercano a cero (-0.014), y el gráfico de dispersión no mostró ninguna tendencia conjunta evidente, saber esto es fundamental, ya que al entender esto podemos justificar el modelar producción de crudo y gas como series temporales univariantes e independientes, descartando la inclusión del precio como variable exógena.

Tanto la producción de crudo como la de gas presentan las características típicas de una serie temporal económica, y cada una de estas características apunta hacia ciertos modelos que pueden funcionar para el propósito de este proyecto.

- **No Estacionariedad:** Esto lo vemos en ambos recursos, la prueba de Dickey-Fuller aumentada (ADF) confirmó estadísticamente mostrándonos un resultado de **p-valor > 0.05**, esta es una característica crítica que cualquier modelo predictivo debe abordar. Modelos como **SARIMA** manejan la no estacionariedad mediante la diferenciación de la serie, modelos como **Prophet** están diseñados para trabajar con tendencias no lineales y cambios dependiente de manera inherente, por otro lado, los modelos de Machine Learning como **XGBoost**, cuando implementan con librerías como **Skforecast**, pueden abordar la no estacionariedad mediante la creación de características basadas en el tiempo o mediante la transformación de la variable objetivo.
- **Tendencia:** Ambas series presentan una tendencia de largo plazo, la producción de crudo muestra una tendencia con varios cambios de pendiente, mientras la que de gas exhibe una tendencia decreciente mucho más marcada y consistente.
- **Estacionalidad:** La descomposición de las series y el análisis de la producción promedio por mes confirmaron la presencia de un patrón estacional anual en ambos casos.
- **Dependencia temporal y autocorrelación:** Las funciones ACF y PACF revelaron una fuerte dependencia de los valores actuales con sus propios valores pasados, con picos significativos



en los primeros rezagos.

Estos hallazgos motivan la selección de diferentes modelos, cada uno con fortalezas particulares para abordar estas características:


- **Prophet** por su capacidad para modelar de forma robusta y flexible la tendencia y la estacionalidad, así como para detectar automáticamente puntos de cambio en la tendencia.
- **Sarima** es un modelo estadístico de referencia para series temporales que presentan estacionalidad y autocorrelación, permitiendo un modelo paramétrico de estos componentes.
- **XGBoost – Skforecast** por su capacidad para capturar relaciones no lineales complejas, gracias a la creación de características basadas en rezagos mediante Skforecast, por su potencial para explotar al máximo la fuerte autocorrelación observada en los datos.

Para la predicción de la producción tanto de crudo como de gas usaremos estos tres modelos y haremos una evaluación comparativa con el objetivo de determinar cuál se desempeña mejor en la predicción.

### 5.3.6 Análisis de Precios

El análisis de precios se basa en una muestra de 144 observaciones mensuales, se examina el comportamiento estadístico y la relación entre los precios del petróleo (USD/barril) y el gas natural (USD/MBtu).


Lo primero que se analizó fue la distribución, la siguiente gráfica nos permite analizar la dispersión de los precios de ambos recursos a lo largo del periodo analizado.



*Ilustración 23: Distribución de Precios: Crudo vs Gas - Elaboración Propia*

- **Petróleo:** Muestra una alta volatilidad y un rango de precios amplio, los valores fluctúan significativamente, con una media de 69.16 USD/barril y una desviación estándar de 20.41 USD, lo que nos indica su variabilidad, el rango intercuartil (de percentil 25 al 75) se sitúa entre 54.85 USD y 81.04 USD, albergando el 50% de las observaciones más comunes, también se muestran valores extremos, con un precio máximo de 122.71 USD y un mínimo histórico de 18.38 USD, registrado en abril 2020, momento en el cual el mercado fue afectado debido a la demanda global.
- **Gas Natural:** Aunque muestra variabilidad, su rango de precios es mucho contenido en términos absolutos, su precio medio es de 3.24 USD/MBtu, con una desviación estándar de 1.34 USD, la mayoría de las observaciones (50%) se concentran entre 2.40 USD y 3.78 USD. A pesar de esta estabilidad relativa, también muestra picos alcanzando un máximo de 8.81 USD, aunque estos eventos son menos frecuentes que en el caso del crudo.

También se realizó un gráfico de dispersión para ver la relación entre ambas variables y poder enterar si las dos variables se mueven conjuntamente.




*Ilustración 24: Relación Entre Precios de Crudo y Gas - Elaboración Propia*

En la gráfica se puede concluir los siguientes análisis

- **Correlación positiva moderada:** En términos simples, cuando el precio del crudo aumenta, el precio del gas también tiende a hacerlo, y viceversa. La relación tiene un coeficiente de correlación de Pearson de **0.629**, lo que indica una asociación lineal moderada fuerte.
- **Dispersión y Divergencia:** La nube de puntos no forma una línea recta perfecta, lo que nos dice que la relación no es determinista, existen periodos donde los precios divergen, un ejemplo de esto es cuando los precios de crudo son extremadamente bajos (cerca de los 20 USD), el gas no cayó a niveles bajos, se mantuvo en torno a 1.5 a 2.0 USD. Esto sugiere que, aunque están relacionados por dinámicas energéticas globales como costos de producción o contratos, cada mercado responde a sus propias dinámicas de oferta y demanda.


También creamos una tabla de precios promedio mensuales que proporciona una visión detallada de la evolución temporal.



*Ilustración 25: Precio promedio precios (Crudo y Gas) - Elaboración Propia*

La grafica muestra que los precios del **crudo** se mantienen entre 64.0 y 71.2 USD/barril, mientras que el **gas** experimenta fluctuaciones más notorias, con precios que se mantienen entre 3.15 y 3.65 USD/MMbtu.

En análisis de precios, también podemos ver los retornos mensuales, este análisis sirve para ver la ganancia o pérdida porcentual del valor de una materia prima, reflejando su rentabilidad, el análisis de los retornos mensuales complementa la visión de los precios absolutos, enfocándose en la volatilidad y la magnitud de los cambios.



*Ilustración 26: Retornos Mensuales - Elaboración Propia*

La grafica de retornos confirma que el **crudo** experimenta movimientos mensuales mucho más pronunciados que el gas, se puede notar cambios positivos como negativos.

- Aumento en el **2021** del +45% reflejando la recuperación postpandemia.
- Caída en el **2022** del -50% evidencia un impacto de mercado particularmente severo.
- Otros años como 2016 (+15%) y 2018 (+5%) muestran movimientos positivos de menor magnitud, mientras que 2015, 2017, 2019 y 2024 registran caídas mensuales de entre -10% y -20%.

Los retornos mensuales del gas se mantienen constantemente en 0.00% durante todos los años presentados, esto podría indicar una limitación en los datos mostrados o un periodo de estabilidad en el mercado de gas, lo más probable es que esta grafica en **gas** muestre retornos anualizados o un subconjunto de datos muy específico.

El análisis conjunto revela que el crudo y gas, ambos siendo combustibles fósiles clave, mantienen una relación positiva moderada, pero también vemos que sus perfiles de riesgo son muy distintos, el

crudo se caracteriza por una alta volatilidad y una gran sensibilidad a eventos macroeconómicos y geopolíticos globales, con fluctuaciones de precios de gran magnitud. El gas, aunque sujeto a sus propias volatilidades y picos de precio, muestra también un comportamiento medio más estable, influenciado por factores estacionales y regionales.

La asimetría en las dinámicas de precio justifica el desarrollo de modelos separados, aunque acoplados mediante variables exógenas cruzadas, un modelo único para ambos commodities tendría dificultades para capturar simultáneamente la alta volatilidad del crudo y la fuerte estacionalidad del gas.

## 5.4 Modelos de Predicción (Producción)

Basándonos en los hallazgos de los análisis ya realizados, ahora trataremos con la construcción de los modelos predictivos para las series de tiempo de producción de petróleo y gas, como se mencionó en secciones anteriores, al no tener una correlación entre la producción, se optó por tomar la decisión de modelar la producción de crudo y gas de forma independiente, esto permite centrar el esfuerzo del modelado en capturar la dinámica temporal de cada serie, caracterizadas por tendencias y estacionalidad identificadas previamente.

### 5.4.1 Modelos de Predicción Crudo

Se explorarán y compararán tres metodologías de diferentes, un modelo de series temporales estadístico (**SARIMA**), un modelo de aprendizaje automático (**XGBoost con SKforecast**) y un modelo de descomposición y regresión (**Prophet**). La comparación sistemática de estos enfoques permitirá seleccionar el modelo más adecuado, considerando tanto su precisión predictiva como su interpretabilidad y alineación con la dinámica de la serie. El proceso de preparación de datos fue crucial y vario según los requisitos de cada modelo.

Lo primero fue la **consolidación de la serie temporal**, los datos de producción originalmente desagregados por campos y operadoras se unificaron para tener una serie mensual de producción total de crudo, el dataframe contiene 140 observaciones desde enero de 2014 hasta agosto de 2025, indexadas por fecha con frecuencia de inicio de mes ('MS').

Para una evaluación rigurosa y realista, se dividió la serie temporal en dos conjuntos de forma secuencial, el 80% de los datos se utilizó para el entrenamiento de los modelos, y el 20% de los datos restantes para prueba, esta evaluación permite evaluar la capacidad predictiva de los modelos en el periodo reciente. Adicional para el modelo XGBoost a diferencia de Prophet y SARIMA, que trabajan directamente sobre la serie univariante, fue necesario la creación de características para capturar la dinámica temporal sin incurrir en **data leakage** (fuga de datos), es decir que el modelo solo usara información del pasado para predecir el futuro, las features creadas a partir de la serie de producción fueron:

- **Rezagos (Lags):** Valores de la producción en meses anteriores.
- **Estacionalidad Cíclica:** Seno y Coseno del mes del año para representar la estacionalidad anual de forma continua.
- **Tendencia:** Un contador lineal simple.
- **Estadísticas Móviles:** Medias móviles y desviación estándar de ventanas pasadas (3, 6, 12 meses), calculadas exclusivamente con datos anteriores al punto de predicción.
- Para la implementación también se utilizó una ventana deslizante de 24 meses, donde cada fecha objetivo, se concatenaban los valores de producción de los últimos 24 meses con las otras features, creando una matriz final de 92 observaciones.

A continuación, se detalla la configuración y el proceso de entrenamiento para cada modelo.

## PROPHET

Es un modelo desarrollado por Facebook que descompone la serie de tiempo en tendencia, estacionalidad y efectos de días festivos, es robusto ante datos faltantes y cambios de tendencia, lo que lo hace adecuado para series con el comportamiento observado en el EDA.

El dataframe se transformó al formato requerido con columnas **ds** (fecha) e **y** (producción total), se desactivaron las estacionalidades semanal y diaria por no ser relevante para datos mensuales. Se realizó una búsqueda en malla para optimizar los hiperparámetros más influyentes del modelo, utilizando el conjunto de test como validación y el Error Absoluto Medio (MAE) como métrica de evaluación, se exploraron 48 combinaciones.

- *changepoint\_prior\_scale*: [0.01, 0.05, 0.1, 0.2]
- *seasonality\_prior\_scale*: [1.0, 5.0, 10.0, 15.0]
- *changepoint\_range*: [0.8, 0.9, 0.95]

El modelo final se entrenó con la mejor combinación encontrada:

- `{'changepoint_prior_scale': 0.1, 'seasonality_prior_scale': 15.0, 'changepoint_range': 0.95}`

## **SARIMA**

Es un modelo estadístico clásico y ampliamente utilizado para series temporales con componentes estacionales, extiende el modelo ARIMA al incluir explícitamente una parte estacional, lo que hace que este modelo sea idóneo para datos como la producción mensual.

El modelo se entrenó directamente sobre la serie de entrenamiento, basado en el EDA que mostro una tendencia no estacionaria y una fuerte estacionalidad anual, se seleccionó una configuración que implica un componente autorregresivo (AR) de orden 1, una diferenciación de orden 1 para hacer la serie estacionaria y una media móvil (MA) de orden 1 con sus respectivos componentes estacionales para un periodo de 12 meses.

## **XGBoost con enfoque Skforecast**

Es un algoritmo de *Gradient Boosting* altamente efectivo para datos tabulares, para aplicarlos a series temporales, se utilizó un enfoque de ventanas deslizantes, donde el problema de predicción se reformula como un problema de aprendizaje supervisado, convirtiendo las observaciones pasadas en variables predictoras.

Con las features creadas y alineadas temporalmente, se generaron las matrices *X* (92 muestras, 32 features) y el vector *y*. Se mantuvo también la misma división 80/20, dando como resultado 73 muestras para entrenamiento y 19 para prueba, se realizó una búsqueda en malla con *GridSearchCV* y *TimeSeriesSplit* (3 divisiones) para encontrar la mejor combinación de hiperparametros, respetando la dependencia temporal de datos.


Para evaluar el rendimiento de los modelos, se utilizaron las siguientes métricas:



- **MAE:** Error Absoluto Medio en barriles, indicando la magnitud promedio de los errores.
- **MAPE:** Error Porcentual Absoluto Medio, ofreciendo una visión relativa del error.
- **R<sup>2</sup>:** Coeficiente de determinación, indicando la proporción de la varianza explicada por el modelo.

Los resultados de la predicción de los modelos fueron los siguientes:


### Prophet



*Ilustración 27: Resultados Modelo Prophet (Crudo) - Elaboración Propia*

El modelo se ajustó a los a los datos históricos aprendiendo de forma correcta los patrones estacionales y la tendencia general presentes en la serie, en la región posterior a la línea de corte (año 2023), donde están los datos de test, datos que el modelo no conocía, se observa que el modelo la tendencia a la baja que había aprendido en los últimos años del entrenamiento. Sin embargo, **no logra capturar los repuntes y volatilidad** que presenta la serie real en este periodo.


## SARIMA



*Ilustración 28: Resultados Modelo SARIMA (Crudo) - Elaboración Propia*

Durante la fase de entrenamiento, el modelo demuestra una capacidad aceptable para capturar la dinámica general de la serie, aprendiendo la tendencia y los patrones estacionales presentes en los datos hasta el punto de corte, el modelo **no logra replicar la volatilidad y los repuntes** de la producción real, aunque al inicio del test, el modelo logra acercarse a los datos reales de la serie, a partir de finales del 2024 se desvía de la producción real, su predicción actúa como un “promedio móvil”. Aunque el MAE (947,082 barriles) no logrando tener mejores resultados que Prophet.

## XGBoost con Skforecast



*Ilustración 29: Resultados Modelo XGBOOST (Crudo) - Elaboración Propia*

La grafica demuestra el ajuste superior del modelo XGBoost, la línea de predicción se superpone casi

perfectamente con la línea de valores reales en la mayoría de los puntos del conjunto de prueba, esta capacidad de seguir la serie real, incluso sus fluctuaciones, es lo que traduce que tenga el MAE más bajo.

Tras evaluar los resultados cuantitativos y el análisis visual de las predicciones, se selecciona el modelo **XGBoost con enfoque Skforecast** como el modelo óptimo para la predicción de la producción mensual de crudo.

- **Rendimiento Superior:** Es el modelo con el MAE (521,913 barriles) y MAPE (2.31%) más bajos, lo que nos indica que las predicciones son mucho más cercanas a los valores reales, su error es aproximadamente 4 veces menor que SARIMA y 7 veces menor que Prophet.
- **Capacidad Predictiva ( $R^2$ ):** Su valor de 0.474 indica que puede explicar casi el 50% de la variabilidad de la producción futura.
- **Flexibilidad y Adaptabilidad:** A diferencia de Prophet y SARIMA, que asumen una estructura de modelo fija, XGBoost es un modelo flexible que puede aprender relaciones no lineales complejas entre las features creadas y la producción, lo cual le permite adaptarse mejor a los cambios en la dinámica del sector, como se evidencia en su capacidad para seguir las fluctuaciones del periodo de prueba.

Por lo tanto, el modelo **XGBoost con Skforecast** es el recomendado para realizar las predicciones futuras de producción de crudo, ofreciendo un balance óptimo entre precisión, capacidad de adaptación a la dinámica del sector y robustez metodológica.

### 5.4.2 Modelos de Predicción Gas

Esta sección se describen los modelos implementados para la predicción de la producción mensual de gas en Colombia. A diferencia de crudo, donde se optó por evaluar directamente los tres modelos, para gas se decidió implementar una comparativa completa entre Prophet, SARIMA y XGBoost, siguiendo las mismas metodologías de ventanas temporales que demostró ser exitosa en el caso de crudo, esta decisión permite validar si el mejor modelo para crudo es también el más adecuado para gas, considerando las diferencias en el comportamiento de ambas series idénticas en el EDA ya mostrado.

El proceso de preparación de los datos siguió los mismos alineamientos que se usaron para crudo, pero adaptado a la característica específicas de la serie de gas.

- Los datos de producción de gas se agregaron para obtener una serie mensual de producción total, el dataframe contiene 140 observaciones desde enero de 2014 hasta agosto de 2025, indexadas por fecha con frecuencia de mes ('MS'). La producción de gas presenta una magnitud mayor que la de crudo, con una media de 59.8 millones de KPC.
- Siguiendo el mismo criterio utilizado para crudo, se dividió la serie temporal en dos conjuntos, 80% de los datos para entrenamiento y el 20% de datos restante para pruebas.
- Para el modelo XGBoost, se replicó el enfoque de ventanas temporales utilizado con crudo, creando las siguientes características sin incurrir en *data leakage* (Rezagos (Lags), Seno y Coseno del mes del año, un contador lineal, Medias móviles y desviación estándar de ventanas pasadas y ventana deslizante de 24 meses).

A continuación, se detalla la configuración y el proceso de entrenamiento para cada uno de los tres modelos evaluados en la predicción de gas.

### **Prophet**

Dada la fuerte estacionalidad anual identificada en el EDA del gas, se consideró un candidato apropiado como baseline interpretable. Se utilizó el formato estándar de columnas *ds* (fecha) e *y* (producción total de gas), también se desactivaron las estacionalidades de menor frecuencia, se realizó una búsqueda en malla similar a la empleada para crudo, explorando combinaciones de *changepoint\_prior\_scale*, *seasonality\_prior\_scale* y *seasonality\_mode*, utilizando el MAE en el conjunto de prueba como métrica de evaluación.

### **SARIMA**

A pesar de su pobre desempeño con crudo, se decidió evaluarlo en gas para mantener la consistencia metodológica y validar si su rigidez estructural es igualmente problemática en esta serie.

### **XGBoost con Skforecast**


el modelo ganador para crudo se implementó siguiendo el mismo enfoque de ventanas deslizantes que convierte el problema de predicción de series temporales en un problema de aprendizaje supervisado, se replicó la búsqueda en malla con *GridSearchCV* y *TimeSeriesSplit* para encontrar la configuración optima específicamente para gas, el espacio de búsqueda incluyó los mismo hiperparametros que para crudo.

Para evaluar el rendimiento de los modelos, se utilizaron las mismas métricas que para crudo:

- **MAE:** Error Absoluto Medio.
- **MAPE:** Error Porcentual Absoluto Medio.
- **R<sup>2</sup>:** Coeficiente de determinación.

Los resultados de la predicción para la producción de gas fueron los siguientes:


### Prophet



*Ilustración 30: Resultados Modelo Prophet (Gas) - Elaboración Propia*

Se observa que el modelo captura adecuadamente la tendencia descendente de largo plazo, el modelo dio un valor alto en su R<sup>2</sup> (0.8260), sin embargo, la línea de predicción parece no seguir las fluctuaciones mensuales, esta incapacidad para reaccionar a la volatilidad de corto plazo se refleja en un MAPE de 100.57% indicando que los errores proporcionales son tan grandes, Prophet entiende hacia dónde va la producción, pero falla en predecir cuanto será en un mes específico.


## SARIMA



*Ilustración 31: Resultados Modelo SARIMA (Gas) - Elaboración Propia*

La grafica de SARIMA revela un comportamiento mixto, el modelo sigue la tendencia descendente, pero con un sesgo sistemático a la baja, subestimando la producción en la mayoría de los puntos del conjunto de prueba, tiene un MAE de **2,962,391 KPC**, el más alto de los tres modelos, indicando errores considerables, la franja de confianza se hace grande hacia el futuro, reflejando la incertidumbre, pero no oculta la deficiencia del modelo.

## XGBoost – Skforecast



*Ilustración 32: Resultados Modelo XGBOOST (Crudo) - Elaboración Propia*

Esta gráfica, permite una comparación visual directa, la línea de predicción de XGBoost se acerca a

los valores reales en el conjunto de prueba, a diferencia de Prophet, no suaviza en exceso; a diferencia de SARIMA, no subestima sistemáticamente, el modelo logra seguir tanto la tendencia descendente como las fluctuaciones mensuales específicas de la producción de gas. El MAE de 1,386,043 KPC, aunque superior al de Prophet en términos absolutos, pero el MAPE de 3.45% es el más bajo de los tres modelos, indicando que los errores consistentemente pequeños en proporción al valor real.

Tras evaluar los resultados cuantitativos y el análisis visual de las predicciones, se selecciona el modelo XGBoost como el modelo óptimo para la predicción de la producción de hidrocarburos. El MAPE de 3.45% es el más bajo de los tres modelos, mejorando por mucho el valor proporcionado por el modelo Prophet, esto demuestra que XGBoost es el único modelo que mantiene errores pequeños y consistentes independientemente de la magnitud de la producción.

Mientras SARIMA subestima sistemáticamente y Prophet sobreestima en ciertos puntos, la gráfica de predicción demuestra que XGBoost es el único modelo capaz de seguir las fluctuaciones mensuales de la producción de gas.

## 5.5 Modelos de Predicción (Precios Commodities)

### 5.5.1 Predicción precio crudo

El análisis exploratorio de datos realizado anteriormente mostraron hallazgos fundamentales que orientaron a la estrategia de modelización para los precios de los commodities energéticos, diferente de la producción, donde la baja correlación de los precios justifico un enfoque univariante, para los precios se identificó una correlación positiva moderada (0.629) entre el precio del crudo y el precio del gas, lo que abre la posibilidad de utilizar modelos que incorporen esta interdependencia.

El EDA evidencio características distintivas en cada serie, el crudo presenta una volatilidad del 40.4%, con una caída histórica pronunciada durante la pandemia del COVID 19 en abril del 2020 (Precio mínimo 18.38 USD), Pero también un alza fuerte en el año 2022 debido a la guerra de Ucrania (122 USD), el precio del gas muestra una volatilidad aun mayor (59.6%) y una distribución de precios más concentrada en rangos bajos.

Estos hallazgos condicionan la selección de los modelos, por un lado, la naturaleza volátil y no estacionaria de ambas series, la correlación identificada sugiere que el precio del gas podría ser un predictor relevante para el precio del crudo o viceversa, funcionando como **variable exógena** que capture dinámicas compartidas del mercado energético global.

Lo primero será hacer el uso del modelo Prophet con regresores externos, se predecirá crudo y se usará un enfoque de descomposición estructural podría beneficiarse de la inclusión de gas como covariable.

El proceso de preparación de los datos requiere un tratamiento específico, dada la naturaleza financiera de las series y la inclusión de variables exógenas. Se cargo un dataset con las variables de precios de crudo y gas, el dataset cuenta con 144 observaciones mensuales, indexado por fecha.

Se realizo la división de datos siguiendo el mismo criterio utilizado para producción, 80% de los datos fueron usados para entrenamiento y 20% para pruebas.

A continuación, se detalla el proceso de entrenamiento para el modelo de predicción de precio de crudo.

### **Prophet**

Una de las ventajas de este modelo en este caso es la capacidad de incorporar regresores externos (variables exógenas) que puedan mejorar la precisión de las predicciones, Prophet se presenta como una opción natural para evaluar la inclusión del precio del gas como covariable permite capturar dinámicas compartidas del mercado energético.

Al igual que con crudo se tuvo que realizar las transformaciones del dataset de acuerdo con lo que solicita Prophet, el formato requerido.

- ds = fecha (índice temporal)
- y = precio del crudo (variable objetivo)
- gas = precio del gas (regresor externo)

Se desactivaron las estacionalidades semanales y diarias por no ser relevantes para datos mensuales,



manteniendo la estacionalidad anual que el modelo detecta automáticamente. También se realizó una búsqueda de malla exhaustiva para encontrar la combinación óptima de hiperparámetros que minimice el error en el conjunto de prueba.


El resultado del modelo fue el siguiente, aun teniendo los mejores hiperparámetros.



*Ilustración 33: Predicciones Prophet (Precios) - Elaboración Propia*

El gráfico y las métricas obtenidas revelan un desempeño preocupante del modelo, El MAE en entrenamiento (10.27 USD) es significativamente menor que en prueba (14.63 USD), lo que indica un problema de sobreajuste (*overfitting*), el modelo aprende demasiado bien los patrones históricos, pero falla al generalizar los nuevos datos, el  $R^2$  negativo indica que el modelo es peor que predecir la media histórica.

Después de un análisis de los resultados del modelo, se encontró que la correlación entre los precios del crudo y el precio del gas, segmentado por los conjuntos de entrenamiento y prueba, revela un fenómeno crítico que explica el pobre desempeño de los modelos que utilizan el gas como variable exógena.



*Ilustración 34: Correlación Precios Train-Test - Elaboración Propia*

Durante el periodo de entrenamiento (115 observaciones, enero 2014 – julio 2023), se observa una correlación positiva fuerte de **0.7436** entre el precio del crudo y gas, este valor es incluso superior a la correlación que se evidencio en el análisis (Puntos azules en la gráfica).

Aunque en la correlación de Prueba (29 observaciones, agosto 2023 - diciembre 2025), la correlación se invierte drásticamente a **-0.5586**, una correlación negativa moderada (Puntos rojos). Este hallazgo explica porque el desempeño de Prophet fue tan mal, el modelo cuando está en la fase de entrenamiento aprendió que cuando el gas sube, el crudo también lo hace, pero al momento de llegar al conjunto de prueba se encontró lo opuesto totalmente (cuando el gas sube, el precio baja), el modelo no solo falla, sino que activamente predice en la dirección equivocada porque su conocimiento del pasado es ahora una desventaja.

Por lo cual se trabajará de la misma forma en que se trabajó las predicciones de producción de crudo y gas, solo se trabajará con los valores de los precios de crudo y su serie temporal, y con los valores de los precios de gas con su serie temporal.


Para esto se trabajará con los modelos XGBoost para ver cómo se comporta ya que como se mencionó en producción, el modelo es bueno para trabajar con series temporales no lineales, también un estudio mostro que el uso de un modelo hibrido LSTM-GRU puede predecir los precios de los commodities, esta combinación de los modelos ayuda en el análisis de la volatilidad del mercado integrando variables macroeconómicas y geopolíticas.

Para la preparación de los datos se realizó de igual forma la división de los datos de un 80% de los

datos para entrenamiento y 20% restante de los datos para prueba. Para el modelo XGBoost, se creó un conjunto exhaustivo de características utilizando exclusivamente información disponible hasta el momento de la predicción.

Los resultados de los dos modelos son los siguientes:


### XGBoost – Skforecast



*Ilustración 35: Resultados Modelo XGBOOST (Precio Crudo) - Elaboración Propia*

La grafica muestra el desempeño del modelo XGBoost en la predicción del precio mensual del crudo, mostrando que lo mejor era no incluir el precio de gas como variable exógena, mostrando un rendimiento sobresaliente en la predicción del precio del crudo. Su MAE de 2.91 USD y su  $R^2$  de 0.7889 lo posicionan como un buen modelo, la capacidad de XGBoost para manejar relaciones no lineales y su robustez ante cambios estructurales lo convierten en una herramienta mucho más fiable para este problema.

## Modelo LSTM-GRU



*Ilustración 36: Resultados Modelo LSTM – GRU (Precio Crudo) - Elaboración Propia*

La grafica muestra el desempeño del modelo hibrido LSTM-GRU en la predicción de precio mensual, mostrando que el modelo sigue adecuadamente la tendencia en el conjunto de prueba, aunque con desviaciones notable, especialmente en los puntos de mayor volatilidad, el MAE del modelo fue de **2.86 USD**, ligeramente inferior al de XGBoost, lo que indica que en términos de error absoluto promedio es superior por poco, en cuanto al MAPE (4.19%) es peor que el modelo XGBoost, lo que sugiere que los errores proporcionales son ligeramente mayores, en cuanto al  $R^2$  (0.4976) inferior al de XGBoost, indicando que XGBoost explica casi un 30% más de la variabilidad de los datos.

Tras evaluar los resultados cuantitativos y el análisis visual de las predicciones se selecciona el modelo XGBoost como el modelo óptimo para la predicción de precio mensual de crudo, esto debido a su rendimiento superior, su robustez y su forma de adaptarse ante cambios estructurales.


El análisis exploratorio de datos realizado en la sección anterior revelo hallazgos que ayudaron a tomar decisiones sobre el proceso de modelado para el precio del gas, para este proceso, la predicción del precio de gas se adoptara una estrategia exclusivamente univariante, utilizando únicamente la historia del propio precio del gas, los modelos que aprende los patrones intrínsecos de la serie objetivo será más robusto que uno que depende de predictores externos inestables, adoptando el mismo enfoque que se utilizó para la predicción de crudo y mostro buenos resultados.

Para la preparación de datos se obtuvo un dataframe con los datos únicamente de los precios de gas,

conteniendo un total de 144 observaciones mensuales, indexadas por fecha, la serie presenta una media de 3.24 USD/MMBTU y una desviación estándar de 1.34 USD, con una volatilidad anualizada del 59.6%, superior a la de crudo. El dataset también fue dividido con 80% de los datos para entrenamiento de los modelos y 20% de los datos para pruebas, los modelos usados fueron XGBoost – Skforecast y un modelo híbrido LSTM – GRU.

El resultado de los modelos fueron los siguientes.

### XGBoost - Skforecast




*Ilustración 37: Resultados Modelo XGBOOST (Precio Gas) - Elaboración Propia*

La grafica muestra el resultado del modelo XGBoost con Skforecast, el modelo aprende sin problema los patrones históricos de la serie, en el conjunto de prueba se evidencia que el modelo logra seguir adecuadamente la tendencia de la serie original, aunque se observan algunas desviaciones notables, mostrando algunas dificultades para anticipar adecuadamente algunos picos de la volatilidad, mostrando un comportamiento más suavizado que la serie real.

En cuanto a las métricas de evaluación se evidencio que el modelo muestra que el MAE (0.41 USD) da una precisión notable considerando que los precios oscilan entre 2 y 9 USD en el periodo de prueba, el MAPE (15.77%) da un valor razonable entendiendo que la serie presenta una alta volatilidad y cambios estructurales, el  $R^2$  (0.5996) indica que el modelo explica casi el 60% de la variabilidad de los precios en el conjunto de prueba, un resultado solido para una serie financiera volátil.

## LSTM – GRU



*Ilustración 38: Resultados Modelo LSTM – GRU (Precio Gas) - Elaboración Propia*

La grafica muestra que el modelo presenta dificultades significativas para la predicción del precio del gas, la predicción, mostrando que el modelo no logra capturar los cambios pronunciados de la serie original, los resultados numéricos confirman el pobre desempeño visual del modelo.

El MAE es de 0.80 USD, indicando que LSTM-GRU comete errores absolutos significativamente mayor, el MAPE es de 21.66%, reflejando una peor precisión relativa, el  $R^2$  es de -1.666 un valor negativo mostrando que el resultado es peor que el de Prophet con crudo (-2.96), indicando que el modelo es peor que predecir la media histórica.

Tras ver los resultados de las predicciones se optará por usar el modelo XGBoost para la predicción del precio del gas, esto debido a que tiene un rendimiento superior, mejores valores numéricos en las evaluaciones de desempeño, mostrando que XGBoost ha sido el mejor modelo para cada caso que se ha querido evaluar en este proyecto.

## 5.6 Resultados Modelos Predicción

Una vez implementados y mejorados los diferentes modelos predictivos para cada una de las variables objetivo (producción crudo y gas, precios commodities crudo y gas), se procedió a evaluar su desempeño comparando las métricas de evaluación, el propósito de esta sección es mostrar los resultados obtenidos, organizados en tablas comparativas que facilitan la identificación del modelo

óptimo para cada caso.

La evaluación se realizó sobre el **conjunto de prueba (test)**, correspondiente al 20% de los datos más recientes, es decir que la evaluación esta entre los periodos 2023 – 2025, respetando la secuencia temporal para garantizar que las métricas reflejen la verdadera capacidad predictiva de los modelos ante datos no vistos.

Las métricas de evaluación son:

- MAE, Error Absoluto Medio el cual indica la magnitud promedio de los errores de predicción en unidades originales.
- MAPE, Error Porcentual Absoluto Medio, expresa el error como proporción del valor real
- $R^2$ , Coeficiente de determinación indicando la proporción de varianza de la variable dependiente que es explicada por el modelo.

### 5.6.1 Resultados Predicción Crudo


La siguiente tabla presenta los resultados obtenidos por los tres modelos evaluados para la predicción de la producción mensual de crudo.

*Tabla 1: Resultados Predicción Crudo*

| Modelo             | MAE (barriles) | MAPE         | $R^2$         |
|--------------------|----------------|--------------|---------------|
| Prophet optimizado | 914,527        | 3.98%        | -86.67%       |
| SARIMA optimizado  | 950,372        | 4.15%        | -1.18%        |
| XGBoost directo    | <b>427,795</b> | <b>1.89%</b> | <b>0.6320</b> |

Los resultados muestran que **XGBoost** tiene mejores métricas de evaluación que los demás modelos, para comprender las razones de porque el modelo obtuvo mejores resultados, se analizaron dos métricas importantes, las cuales son:

## Importancias de Features



*Ilustración 39: Importancia Features (Producción Crudo) – Elaboración Propia*


El grafico de importancia de features revela los predictores más influyentes en el modelo XGBoost para la producción de crudo.

- El factor más importante: la producción sigue una tendencia de largo plazo.
- Media móvil de 3 meses: captura la dinámica de corto plazo.
- Rezago de 24 meses: incorpora patrones de largo plazo y estacionalidad.
- Días del mes: corrige por diferencias en días hábiles/productivos

Con una importancia cercana al 50%, la tendencia lineal es el predictor más relevante, esto demuestra que la producción de crudo en Colombia tiene una fuerte inercia de largo plazo, y que capturarla es importante para cualquier modelo predictivo.



## SHAP Values



*Ilustración 40: SHAP valúes (Producción Crudo) - Elaboración Propia*

El análisis SHAP (SHapley Additive exPlanations) completa la importancia de features mostrando como impacta cada variable en las predicciones, es decir si aumenta o disminuya el valor predicho, en esta imagen observamos.

- **Tendencia** valores positivos y negativos simétricos indicando que la tendencia ajusta las predicciones hacia arriba o abajo según su valor.
- **días\_mes** confirma que los meses con más días calendario tienden a tener mayor producción predicha.
- **Lags(\_13,\_2) y ma3** son rezagos y medias móviles muestran que la historia reciente es importante

XGBoost tiene mejores resultados porque pudo incorporar más información relevante y porque su arquitectura basada en arboles le permitió capturar relaciones no lineales que los demás modelos no pueden.

## 5.6.2 Resultados Predicción Gas

La siguiente tabla presenta los resultados obtenidos por los modelos evaluados para la predicción de la producción mensual de gas.

*Tabla 2: Resultados Predicción Gas*

| Modelo  | MAE<br>(kpc)     | MAPE         | R <sup>2</sup> |
|---------|------------------|--------------|----------------|
| Prophet | 1,072,042        | 100.57%      | 0.8260         |
| SARIMA  | 2,962,391        | 7.15%        | -0.05          |
| XGBoost | <b>1,386,034</b> | <b>3.45%</b> | <b>0.5524</b>  |


Los resultados para gas presentan métricas que requieren más cuidado para su evaluación que la de crudo.

- MAE, XGBoost tiene un mejor resultado que SARIMA, pero Prophet tiene mejores resultados que los dos modelos en términos absolutos, sin embargo, no se puede seleccionar un modelo solo porque su MAE fue más bajo.
- MAPE, aquí la diferencia es grande XGBoost logra el valor más bajo, mientras que Prophet tiene el valor más alto, un MAPE de 100.57% como el de Prophet significa, que, en promedio, los errores son tan grandes como los valores que trata de predecir.
- R<sup>2</sup> de Prophet es bueno, sin embargo, este valor debe interpretarse junto con el MAPE, XGBoost explica el 55% de la variabilidad, un resultado sólido considerando la alta volatilidad del gas.

Prophet captura tendencia, pero con errores proporcionales enormes, acierta cuando la producción es baja por eso su MAE es mejor, pero cuando la producción es alta o hay volatilidad sus errores son enormes, por eso su MAPE es grande, mientras que XGBoost tiene errores consistentes y proporcionalmente pequeños en toda la serie.

También sacamos las dos métricas que usamos con la producción de crudo para ver porque XGBoost fue el mejor modelo para la producción de gas.


**Importancia de Features**



*Ilustración 41: Importancia Features (Producción Gas) – Elaboración Propia*

EL grafico muestra que los features (\_28, 32, 23) rezagos recientes, muestran que la producción del último trimestre es muy importante, los rezagos estacionales (\_85, 90, 92) patrones anuales y bianuales también ayudan en la predicción.

**SHAP Values**



*Ilustración 42: SHAP valúe (Producción Gas) - Elaboración Propia*

El análisis SHAP muestra que las tres primeras features (rezagos recientes) tienen los mayores impactos, tanto positivos como negativos en las predicciones.

### 5.6.3 Resultados Predicción Precio Crudo

La siguiente tabla presenta los resultados obtenidos por los dos modelos evaluados para la predicción del precio mensual de crudo, Prophet fue descartado debido a que no obtuvo buen desempeño debido al cambio estructural en la correlación de los precios de crudo y gas.

*Tabla 3: Resultados Predicción Precio Crudo*


| Modelo   | MAE                | MAE                | MAPE         | R <sup>2</sup> Test |
|----------|--------------------|--------------------|--------------|---------------------|
|          | Train              | Test               | Test         |                     |
| XGBoost  | <b>0.12</b><br>USD | 2.91<br>USD        | 3.96%        | <b>0.7889</b>       |
| LSTM-GRU | 5.55<br>USD        | <b>2.63</b><br>USD | <b>3.80%</b> | 0.5308              |

Los resultados muestran que los modelos mucho más equilibrados que con la producción notando lo siguiente:

- MAE: LSTM obtiene un MAE ligeramente menor que XGBoost en los datos de prueba
- MAPE: ambos modelos están cerca, solo una diferencia de 0.16% de diferencia
- R<sup>2</sup>: Aquí XGBoost muestra una ventaja significativa mostrando que XGBoost explica el 78% de la variabilidad de los precios, mientras que LSTM solo explica el 53%
- MAE Train: Acá en este punto esta la diferencia, XGBoost muestra un sobreajuste moderado, 0.12 USD en train, mientras que LSTM presenta un sobreajuste severo de 5.55 USD en train, lo que indica que la red neuronal tuvo dificultades para aprender patrones generalizables.

Para comprender porque XGBoost logro una capacidad explicativa muy superior a pesar de un MAE ligeramente mayor, se analizaron la importancia de las features y valores SHAP.

## Features importantes




*Ilustración 43: Importancia Features (Precio Crudo) – Elaboración Propia*

Se evidencia en el grafico de importancia de rezagos que los más importantes fueron:

- **Feature\_21** el predictor más importante, rezagos de 21 meses o estadísticas de ventanas larga.
- **Feature\_47** medida de volatilidad de largo plazo
- **Feature\_9** Rezagos de corto plazo

El feature\_21 concentra la importancia total, indicando que el patrón dominante, rezagos estacionales o una medida móvil que el modelo aprendió como crítico, algo también que se nota es que después de los tres primeros predictores, el resto de caer rápidamente lo que indica que el modelo se apoya en un núcleo reducido de features.

## SHAP Values



*Ilustración 44: SHAP valúes (Precio Crudo) - Elaboración Propia*

El análisis SHAP muestra información aún más detallada sobre el impacto de las features:

- Feature\_9 tiene el rango más amplio indicando que esta variable puede ajustar el precio predicho en un rango significativo dependiendo de su valor, siendo un predictor influyente.
- feature\_21 muestra rangos de impactos significativos, confirmando que es una feature importante y central del modelo.
- Feature 47 tiene un impacto más moderado pero consistente para el modelo.

Aunque LSTM-GRU tiene márgenes muy estrechas en MAE, MAPE, la ventaja abrumadora de XGBoost en  $R^2$  es el factor decisivo, un modelo que puede explicar el 78% de la variabilidad de los precios es más confiable que uno que explica solo el 53%. Por eso XGBoost fue seleccionado como el mejor modelo, su MAE y MAPE están cercanos a LSTM-GRU, el equilibrio de XGBoost entre precisión y capacidad explicativa muestran que es el modelo más fiable para este propósito.

### 5.6.4 Resultados Predicción Precio Gas

La siguiente tabla presenta los resultados obtenidos por los modelos evaluados para la predicción

de precio mensual de gas.

Tabla 4: Resultados Predicción Precios Gas

| Modelo   | MAE      | MAE Test        | MAPE          | R <sup>2</sup> Test |
|----------|----------|-----------------|---------------|---------------------|
|          | Train    |                 | Test          |                     |
| XGBoost  | 0.02 USD | <b>0.41 USD</b> | <b>15.77%</b> | <b>0.5996</b>       |
| LSTM-GRU | 0.70 USD | 0.73 USD        | 19.51%        | -1.4024             |

Los resultados muestran una superioridad de XGBoost sobre LSTM-GRU en todas las métricas evaluadas:

- MAE: XGBoost alcanza un error casi menor a la de LSTM-GRU, en términos generales XGBoost se desvía en promedio 41 centavos, mientras LSTM se desvía 73 centavos.
- MAPE: XGBoost logra un mejor valor que LSTM
- R<sup>2</sup>: XGBoost logra explicar casi el 60% de la variabilidad de los precios, mientras que LSTM tiene valores negativos, lo que significa que es peor que predecir solamente la media histórica.

Para comprender las predicciones de XGBoost en el precio del gas, se analizaron la importancia de las features y los valores SHAP.

Features Importantes





Ilustración 45: Importancia Features(Precio Gas) - Elaboración Propia

El grafico de importancia de features más influyentes en el modelo fueron:

- Feature\_20 rezagos de 20 meses, el predictor más importante.
- Feature\_37 media de volatilidad.
- Feature\_50 tercer predictor clave.

Para las predicciones de precios de gas, a diferencia de los precios de crudo donde una feature dominaba sobre las demás, en gas es más equilibrada, esto responde a una combinación más diversa de factores.

### SHAP Values



*Ilustración 46: SHAP Values(Precio Gas) - Elaboración Propia*

El análisis SHAP muestra información detallada sobre como cada feature en las predicciones, mostrando lo siguiente:

- Feature\_37,9,21 son las tres variables que muestran los rangos de impactos más significativos indicando que estas features pueden ajustar el precio predicho en más de 1 USD/MMBTU.



- Feature\_35,\_20,\_34 son variables que tienen impactos moderados.
- Feature\_17,\_36,\_18 son variables pequeñas, pero no despreciables.

La superioridad de XGBoost frente a LSTM es indiscutible en todas las métricas evaluadas.

### 5.6.5 Resultados Predicción Precio Gas

El análisis de los modelos de predicción implementados para las cuatro variables objetivo confirma que ya lo antes dicho que el modelo de Machine Learning XGBoost, en los cuatro casos de estudio, mostro una versatilidad y robustez, mostrando que es un modelo confiable para la predicción de series temporales energéticas en el contexto colombiano.

Algo que también es notorio en estos análisis es que se confirma que los modelos estadísticos tradicionales no presentaron un buen desempeño, mientras que el modelo de Deep Learning debido a su arquitectura no logra dar resultados positivos debido a la limitación de datos insuficientes para entrenar redes neuronales.

El éxito de XGBoost se fundamenta en un feature engineering exhaustivo pero riguroso, que incluyo rezagos múltiples de hasta 24 meses, estadísticas móviles, medidas de volatilidad, transformaciones cíclicas y tendencias explícitas, esta información permitió al modelo capturar la dinámica temporal desde múltiples perspectivas.

## 5.7 Proyecciones y Decisiones

Una vez seleccionados y validados los modelos predictivos para cada variable objetivo, se procedió a generar **predicciones a 12 meses** utilizando la totalidad de los datos, este enfoque permite aprovechar al máximo la información existente para proyectar el comportamiento futuro del sector energético en Colombia.

Las predicciones generadas dan una base para la construcción de escenarios en los que se puede generar proyecciones y ayude a la toma de decisiones en ámbitos como inversiones financieras, inversiones en infraestructura, etc.

### **5.7.1 Metodología para la generación de predicciones**


Para asegurar la consistencia y la confiabilidad de las proyecciones, se siguió el mismo pipeline utilizado durante la fase de entrenamiento y validación de los modelos.

- Cada modelo ganador, en este caso XGBoost en los cuatro escenarios fue reentrenado utilizando el 100% de los datos.
- Se replicó exactamente el mismo proceso de creación de features utilizado en la fase de modelización, incluyendo rezagos, medias móviles, estadísticas de volatilidad y transformaciones cíclicas.
- Para las proyecciones de los 12 meses siguientes se utilizó un enfoque donde las predicciones de meses anteriores se incorporan como insumos para las predicciones siguientes.
- Los resultados de las predicciones fueron guardados en un dataset para posteriormente ser enviados al DWH para la creación del dashboard de análisis.

### **5.7.2 Resultados de las Predicciones 12 Meses**

A continuación, se presentan los resultados de cada variable, los gráficos muestran la extensión de la serie histórica hasta el periodo proyectado.

**Predicción de Producción de Crudo**



*Ilustración 47: Predicción Producción Crudo - Elaboración Propia*

La grafica muestra la evolución histórica de la serie y la proyección para los siguientes 12 meses, se puede observar una continuación de la tendencia descendente que la serie ha mostrado en los últimos años, consistente con el agotamiento natural de los campos maduros, la falta de nuevos proyectos de exploración y perforación debido a los cambios políticos que también tiene un efecto secundario.

*Tabla 5: Resultados Predicción Crudo - 12 meses*

| Mes             | Producción<br>(barriles) | Crudo |
|-----------------|--------------------------|-------|
| Septiembre 2025 | 22,386,810               |       |
| Octubre 2025    | 23,246,340               |       |
| Noviembre 2025  | 22,375,910               |       |
| Diciembre 2025  | 23,241,530               |       |
| Enero 2026      | 23,288,310               |       |
| Febrero 2026    | 21,091,170               |       |
| Marzo 2026      | 23,180,330               |       |
| Abril 2026      | 21,720,170               |       |

|                         |                    |
|-------------------------|--------------------|
| Mayo 2026               | 23,286,850         |
| Junio 2026              | 22,175,480         |
| Julio 2026              | 23,216,240         |
| Agosto 2026             | 23,358,250         |
| <b>Total Período</b>    | <b>273,967,389</b> |
| <b>Promedio Mensual</b> | <b>22,830,616</b>  |

El análisis de la proyección muestra:

- La producción de crudo proyectada para los próximos 12 meses tiene un promedio mensual de 22.83 millones de barriles.
- En la gráfica se observa una estacionalidad mensual con picos en los meses de enero, marzo, mayo y agosto, con caídas en febrero, abril y junio, consistente con los patrones identificados durante el análisis exploratorio.
- El intervalo de confianza es de  $\pm 427,795$  barriles mensuales, por lo cual se podría decir que el rango probable de la producción estaría entre 22.40 y 23.26 millones de barriles para el promedio mensual.

### Predicción de Producción Gas




Ilustración 48: Predicción Producción Gas - Elaboración Propia

La grafica de predicción para la producción de gas muestra un comportamiento totalmente diferente a la de la producción de crudo, aunque la proyección también muestra una tendencia descendente.


*Tabla 6: Resultados Predicción Gas - 12 meses*

| Mes                     | Producción Gas (kpc) |
|-------------------------|----------------------|
| Septiembre 2025         | 37,427,150           |
| Octubre 2025            | 35,980,310           |
| Noviembre 2025          | 37,139,550           |
| Diciembre 2025          | 36,967,100           |
| Enero 2026              | 34,585,240           |
| Febrero 2026            | 36,845,040           |
| Marzo 2026              | 37,111,740           |
| Abril 2026              | 37,778,780           |
| Mayo 2026               | 34,121,380           |
| Junio 2026              | 35,560,090           |
| Julio 2026              | 36,224,270           |
| Agosto 2026             | 33,858,520           |
| <b>Total Período</b>    | <b>433,599,170</b>   |
| <b>Promedio Mensual</b> | <b>36,133,264</b>    |

Para la proyección de gas podemos sacar los siguientes análisis:

- La proyección de gas para los siguientes 12 meses tiene un promedio mensual de 36.13 millones de kpc
- Se observa una mayor estabilidad, los valores oscilan entre 33.9 y 37.8 millones de kpc, la gráfica muestra ciertos picos en marzo y abril.
- El intervalo de confianza es de  $\pm 1,386,034$  kpc mensuales, así que la proyección podría estar entre 34.75 y 37.52 millones de kpc para el promedio mensual.

**Predicciones Precio Crudo**



*Ilustración 49: Predicciones Precio Crudo - Elaboración Propia*

La predicción del precio del crudo muestra una recuperación moderada después de los mínimos de 2025, situándose en niveles alrededor de 65-68 USD/barril.


*Tabla 7: Resultados Predicción Precio Crudo - 12 meses*

| Mes             | Precio<br>(USD/barril) | Crudo |
|-----------------|------------------------|-------|
| Enero 2026      | 62.53                  |       |
| Febrero 2026    | 62.49                  |       |
| Marzo 2026      | 63.38                  |       |
| Abril 2026      | 64.46                  |       |
| Mayo 2026       | 66.00                  |       |
| Junio 2026      | 67.53                  |       |
| Julio 2026      | 68.32                  |       |
| Agosto 2026     | 68.46                  |       |
| Septiembre 2026 | 68.60                  |       |
| Octubre 2026    | 68.88                  |       |
| Noviembre 2026  | 68.86                  |       |
| Diciembre 2026  | 68.81                  |       |
| Promedio 2026   | 66.53                  |       |

De la proyección del precio de crudo podemos obtener los siguientes análisis:

- El precio del crudo muestra una tendencia creciente a lo largo del año, iniciando en 62.5 USD/barril en enero, existen variables externas, como variables geopolíticas que pueden impactar de una manera fuerte en el precio del crudo (la guerra de Irán en estos momentos) que los modelos no pueden predecir.
- La tendencia muestra un crecimiento en el precio lo que sugiere una recuperación gradual de los precios.

**Predicciones Precio Gas**



*Ilustración 50: Predicciones Precio Gas - Elaboración Propia*

La predicción para el precio del gas muestra una caída leve respecto a los valores del 2025.

*Tabla 8: Resultados Predicción Precio Gas - 12 meses*

| Mes          | Precio<br>(USD/MMBTU) | Gas |
|--------------|-----------------------|-----|
| Enero 2026   | 4.28                  |     |
| Febrero 2026 | 4.11                  |     |
| Marzo 2026   | 3.77                  |     |
| Abril 2026   | 3.66                  |     |

|                      |             |
|----------------------|-------------|
| Mayo 2026            | 3.53        |
| Junio 2026           | 3.47        |
| Julio 2026           | 3.44        |
| Agosto 2026          | 3.41        |
| Septiembre 2026      | 3.41        |
| Octubre 2026         | 3.44        |
| Noviembre 2026       | 3.46        |
| Diciembre 2026       | 3.29        |
| <b>Promedio 2026</b> | <b>3.61</b> |

De la proyección del precio del gas podemos analizar lo siguiente:

- El precio del gas presenta una tendencia decreciente a lo largo del año, comenzando en 4.28 USD/MMBTU promedio mensual y descendiendo gradualmente hasta 3.29 USD/MMBTU promedio mensual.
- Esta tendencia refleja un retorno a niveles históricos medios después del pico extraordinario de 2023.

Una vez teniendo los datos de las predicciones, estas predicciones fueron enviadas al DWH construido para creación del dashboard.




Ilustración 51: Dashboard Ilustrativo - Elaboración Propia



### 5.7.3 Construcción de Escenarios

Las predicciones puntuales presentadas en la sección anterior constituyen la expectativa más probable para la evolución de variables durante los próximos 12 meses, sin embargo, en entornos caracterizados por alta volatilidad y cambios estructurales como lo es el mercado energético, la planificación basada solamente en un valor determinista puede ser riesgoso e insuficiente.

Ante esto, se hace necesario complementar las predicciones puntuales con un análisis de escenarios que permitan:

- Cuantificar el rango de posibles resultados ante diferentes condiciones del entorno.
- Identificar umbrales críticos que activen planes de contingencia o decisiones estratégicas.
- Comunicar de manera transparente la incertidumbre asociada a las proyecciones a los tomadores de decisiones.

Para esto se construyó tres escenarios:

- **Escenario base:** Utiliza las predicciones puntuales de precio y producción generado por los modelos.
- **Escenario alza:** En el caso de los precios se llevan al límite superior del intervalo de confianza (predicción + MAE) y se aumentó la tendencia, para el caso de producción solo se llevó al límite superior del intervalo de confianza.
- **Escenario baja:** Se realizó el mismo proceso que con alza solo que se llevaron las predicciones al límite inferior del intervalo de confianza y a los precios se resta tendencia.

A continuación, se muestran los resultados de los escenarios por variable.


**Precio Crudo**



*Ilustración 52: Escenario Precios Crudo - Elaboración Propia*

El área sombreada representa el rango de incertidumbre de las proyecciones que se amplía hacia el final del periodo de los escenarios.


**Precio Gas**



*Ilustración 53: Escenarios Precio Gas - Elaboración Propia*

El área sombreada representa el rango de incertidumbre de las proyecciones que se amplía hacia el final del periodo de los escenarios.


**Producción Crudo**



*Ilustración 54: Escenarios Producción Crudo - Elaboración Propia*

El área sombreada representa el rango de incertidumbre de las proyecciones que se amplía hacia el final del periodo de los escenarios.

**Producción gas**



*Ilustración 55: Escenario Producción Gas - Elaboración Propia*

El área sombreada representa el rango de incertidumbre de las proyecciones que se amplía hacia el final del periodo de los escenarios.

### 5.7.3 Impactos Económicos de los Escenarios

La creación de estos escenarios permite generar múltiples combinaciones de impactos económicos diferentes, para esto se construyó una matriz que cruza los escenarios de producción con los escenarios de los precios calculando el ingreso estimado para cada combinación.

#### Escenarios Crudo

*Tabla 9: Resultados Escenarios Crudo*

| Fecha        | precio_alza<br>production_baja | +<br>precio_baja<br>production_alza | +<br>precio_alza<br>production_base |
|--------------|--------------------------------|-------------------------------------|-------------------------------------|
| 2026-01      | 1.58                           | 1.32                                | 1.77                                |
| 2026-02      | 1.45                           | 1.15                                | 1.59                                |
| 2026-03      | 1.61                           | 1.28                                | 1.78                                |
| 2026-04      | 1.55                           | 1.20                                | 1.68                                |
| 2026-05      | 1.69                           | 1.35                                | 1.90                                |
| 2026-06      | 1.66                           | 1.30                                | 1.85                                |
| 2026-07      | 1.75                           | 1.35                                | 1.95                                |
| 2026-08      | 1.79                           | 1.34                                | 2.00                                |
| <b>Total</b> | <b>13.08</b>                   | <b>10.29</b>                        | <b>14.52</b>                        |

Los resultados permiten concluir estrategias sobre la sensibilidad de los ingresos del sector:

- **Mejor escenario (Precio alza + Producción base):** Con un impacto total de 14.52 millones USD en el periodo analizado, esta combinación representa la situación más favorable, los precios altos, combinados con la producción esperada (escenario base de producción), generan el máximo ingreso adicional, mostrando que el sector en Colombia se beneficia más al alza de precios que de incrementos en producción, este escenario es el más cercano a la realidad en el momento debido al alza en los precios en los últimos días debido a la guerra en Irán.
- **Peor escenario (Precio baja + Producción alza):** Con un impacto total de 10.29 millones USD,

esta combinación muestra que una producción alta, con una caída de precio muestra una reducción de hasta un 29% con respecto al mejor escenario.

- **Escenario mixto(Precio alza + producción baja):** Con 13.08 millones USD, este escenario muestra que precios altos pueden compensar parcialmente una producción baja, pero no alcanza el nivel del mejor escenario.


Con estos escenarios se pueden evaluar estrategias de mercado como:

- Las estrategias de cobertura son más efectivas que las inversiones en aumentar producción a corto plazo.
- Incluso en condiciones adversas, el sector mantiene ingresos positivos, lo que indica resiliencia en el mercado colombiano.

Recomendaciones basadas en los escenarios:

- Para las operadoras evaluar la viabilidad de proyectos de inversión bajo los tres escenarios, no solo la base.
- Las operadoras deberían ajustar el portafolio de coberturas para proteger el margen operativo en escenarios de precios bajos.
- Las entidades territoriales deberían utilizar el escenario base para presupuestación ordinaria, pero mantener reservas equivalentes entre 3 a 6 meses para enfrentar escenarios adversos.
- Las operadoras deberían destinar los ingresos extraordinarios de mejores escenarios para proyectos de desarrollo de largo plazo.

Dado el gran número de combinaciones posibles entre los diferentes escenarios de producción y precios, se creó **un mapa de calor** que permite visualizar de manera integral la sensibilidad de los ingresos del sector ante las variaciones en ambas variables. Este grafico proporciona que se pueda tomar estrategias mucho más fáciles.



*Ilustración 56: Sensibilidad Económica Precio vs Producción (Crudo) - Elaboración Propia*

El mapa de calor revela patrones clave sobre la sensibilidad del sector.

- **Zona de mínimo impacto (zona amarilla):** Zona superior izquierda (Precios bajos + Producción baja), los ingresos se mantienen en el nivel mínimo, pero incluso en condiciones adversas el sector mantiene un mínimo de ingresos.
- **Zona media (Zona naranja):** A medida que aumenta la producción o los precios, los ingresos también inician a crecer de manera gradual. Se observa que la pendiente es un poco más pronunciada en el eje de precios indicando que los ingresos son más sensibles a variaciones en los precios.
- **Zona de máximo impacto (Zona roja):** Parte inferior derecha (Precios altos + producción alta), es la zona donde los ingresos alcanzan su punto máximo, más del doble del escenario base anteriormente plantado, es la zona con mayores condiciones favorables para el sector.

## Escenarios Gas

Se crearon también impactos económicos para los escenarios de producción y precios de gas, los cuales muestran los siguientes análisis


*Tabla 10: Resultados Escenarios Gas*

| Fecha   | precio_alza +<br>production_baja | precio_baja +<br>production_alza | precio_alza +<br>production_base |
|---------|----------------------------------|----------------------------------|----------------------------------|
| 2026-01 | 1.60                             | 1.35                             | 1.80                             |
| 2026-02 | 1.75                             | 1.20                             | 2.00                             |
| 2026-03 | 1.80                             | 0.95                             | 2.05                             |
| 2026-04 | 1.95                             | 0.80                             | 2.15                             |
| 2026-05 | 1.90                             | 0.70                             | 2.00                             |
| 2026-06 | 2.10                             | 0.50                             | 2.30                             |
| 2026-07 | 2.25                             | 0.20                             | 2.45                             |
| 2026-08 | 2.20                             | -0.30                            | 2.40                             |
| Total   | 15.55                            | 5.40                             | 17.15                            |

Los resultados para gas muestran patrones aún más extremos que los observados en crudo:

- **Mejor escenario (Precio alza + Producción base):** Presenta la situación más favorable, los precios altos, combinados con la producción esperada, generan ingresos significativos superiores.
- **Peor escenario (Precio baja + Producción alza):** Indica que, en condiciones extremas de precios bajos, incluso con producción alta, el sector podría generar pérdidas operativas.
- **Escenario mixto (Precio alza + Producción baja):** este escenario muestra que los precios altos pueden compensar una producción baja, alcanzando un 90% del mejor escenario.

De igual modo que en Crudo también se creó un mapa de calor para los escenarios de gas.



*Ilustración 57: Sensibilidad Económica Precio vs Producción (Gas) - Elaboración Propia*

El mapa de calor de gas revela patrones mas pronunciados que el de crudo:

- Zona de mínimo impacto (zona amarilla): Parte superior izquierda (Precios bajos + Producción baja), los ingresos se mantienen a nivel mínimo, en esta zona se refleja la mayor sensibilidad del gas a choques negativos.
- Zona de alto impacto (zona roja): Parte inferior derecha (Precios altos + Producción alta), los ingresos alcanzan su punto máximo, similar a crudo pero alcanzable con variaciones de precios más extremos.

La construcción de escenarios prospectivos y los análisis presentados permiten presentar las predicciones como una herramienta de navegación estratégica de alto valor para el sector energético colombiano.

Los principales aportes de esta sección son:

- Cuantificación de incertidumbre
- Visualización intuitiva de escenarios



- 
- Análisis de sensibilidad
  - Decisiones estratégicas

Este enfoque de escenarios no solo complementa las predicciones puntuales, sino que incorpora también la incertidumbre en el proceso de planificación, permitiendo a los tomadores de decisiones prepararse para diferentes futuros posibles en lugar de tener su análisis en un único resultado, permitiendo crear gestiones de riesgos, asignación de recursos y la definición de estrategias de cobertura en el sector energético colombiano.

## CAPITULO 6. DISCUSION

El desarrollo del proyecto permito alcanzar los objetivos planteados, pero también permitió aprender algunos aspectos importantes en el proceso, limitaciones del proyecto y lecciones aprendidas.

### 6.1 Resultados Principales

Los resultados mostraron la superioridad del modelo XGBoost sobre los demás modelos implementados durante el proyecto y las arquitecturas de Deep Learning, los resultados de los modelos XGBoost se dieron de la siguiente manera:

- Producción de Crudo: MAE de 247,795 barriles.
- Producción de Gas: MAPE de 3.45%.
- Precio Crudo:  $R^2$  de 0.7889.
- Precio Gas: MAE de 0.41 USD.

Estos resultados confirman a pesar del conjunto de datos (144 observaciones) con alta volatilidad y cambios estructurales, los modelos de Machine Learning pueden dar buenos resultados, añadir feature engineering exhaustivos y modelar relaciones no lineales resulto ser determinante para los resultados del modelo.

También algo importante que pudimos notar es que la inversión de correlación entre los precios de crudo y gas, en entrenamiento correlación de +0.7436 y en pruebas -0.5586, este cambio muestra el fracaso de un modelo y se tomó la decisión de sacar gas como variable exógena y adoptar enfoques univariantes para los precios.

### 6.2 Limitaciones del Estudio

#### 6.2.1 Limitaciones por Disponibilidad de Datos

La principal limitación en el proyecto al menos con algunos modelos es la cantidad de los datos

disponibles de la serie temporal de la producción total.

- Con solo 140-144 observaciones mensuales por variable, modelos como los de Deep Learning no se logro obtener todo el potencial, las redes neuronales profundas requieren volúmenes de datos significativamente mayores para entrenarse adecuadamente.
- Los datos de portales abiertos por lo general tienen problemas en la actualización o de carga de datos recientes por posibles retrasos de publicación, publicaciones con datos diarios o semanales podrían haber permitido modelos más precisos.

### **6.2.3 Limitaciones por Factores Externos**

Los modelos predictivos asumen que los patrones históricos se mantendrán en el futuro, pero puede ocurrir variaciones por factores externos:

- Eventos geopolíticos como el conflicto que en estos momentos existe entre Israel e Irán que subieron el precio del crudo, variables que tienen impactos directos e impredecibles, ningún modelo puede anticipar completamente estos eventos, generando incertidumbre no cuantificable.
- El avance de políticas de descarbonización y el crecimiento de energías renovables pueden alterar la demanda de hidrocarburos que podrían afectar a futuro y no se pueden predecir en el alcance del proyecto.
- Modificaciones en la política energética de Colombia (Gobierno de turno, restricciones ambientales), pueden afectar la producción de maneras no anticipadas por los modelos.

## **6.3 Adaptaciones Metodológicas**

El proyecto experimento dos cambios respecto a la metodología planteada.

### **6.2.1 Cambio de Multivariantes a Univariante en Precios**

Inicialmente se contemplo utilizar modelos multivariantes para la predicción de los precios de los commodities, esto aprovechando la correlación que existe entre los precios de crudo y gas, sin

embargo, el hallazgo del cambio estructural de dicha correlación durante el análisis que obligo a replantear la estrategia para el gas, adoptando un enfoque univariante que resulto exitoso (MAPE 3.45%).

Este cambio fue fundamental, ayudo que los modelos pudieran ser entrenados y validados sin encontrar problemas.

### 6.2.2 Evolución del Análisis de Escenarios

El análisis de escenarios evoluciono sobre las predicciones puntuales del modelo ganador a un sistema de graficas de **mapa de calor**, esto entendiendo la gran cantidad de escenarios que se podían plantear y poder responder a la necesidad de comunicar la incertidumbre de manera más efectiva para la toma de decisiones.

### 6.2.2 Impacto de los Resultados

El proyecto ayuda a generar diversos escenarios para tomas de decisiones del futuro de hidrocarburos en Colombia:

- Las predicciones de precios y producción permiten estimar ingresos por regalías con rangos de incertidumbre cuantificados.
- Los mapas de calor pueden ayudar a identificar escenarios críticos y activar planes de contingencia.
- La metodología desarrollada y el proyecto son puntos de partida para estudios más profundos.

## CAPITULO 7. CONCLUSIONES

El presente trabajo de modelización predictiva de la producción y precios de commodities energéticos en Colombia (crudo y gas) ha mostrado hallazgos significativos, a lo cual podemos concluir.

### 7.1 Análisis Exploratorio de Datos

Se identificó una **baja correlación (-0.1369)** entre la producción y los precios de los commodities, lo que justificó la decisión de modelizar estas variables de forma independiente. La producción responde a cambios estructurales mientras que los precios responden a dinámicas de mercado global. Ambas series de producción presentan tendencia no estacionaria y estacionalidad anual, sin embargo, la producción de gas mostró una volatilidad significativamente mayor.

Los precios presentan alta volatilidad, con eventos extremos como caída en el crudo a 18.38 USD en abril del 2020 (efecto pandemia), al igual que alzas significativas 120 USD en 2022 (Guerra Ucrania). La volatilidad anualizada del gas 59% superando a la del crudo 40.4%, indicando un mercado más volátil y menos predecible.

### 7.2 Modelos de Predicción Producción

Para los modelos utilizados en crudo, **XGBoost** demostró ser el modelo más preciso, con un error absoluto de apenas 521,913 barriles y un MAPE de 2.31%. Su capacidad para incorporar múltiples features (rezagos, estadísticas móviles, estacionalidad cíclica) le permitió capturar la dinámica de producción con gran detalle.

Prophet ofreció un desempeño aceptable, capturando tendencia y estacionalidad, pero sin la flexibilidad necesaria para seguir fluctuaciones de corto plazo.

SARIMA fracasó estrepitosamente ( $R^2$  negativo), evidenciando que los modelos estadísticos tradicionales no logran adaptarse a los cambios estructurales en la serie.

Para los modelos utilizados en gas, **XGBoost** se consolidó como el mejor modelo, con un MAPE de

3.45%, significativamente inferior al de Prophet (100.57%) y SARIMA (7.15%). Su capacidad para mantener errores proporcionales consistentes, independientemente de la magnitud de la producción, lo hace la opción más fiable.

Prophet, a pesar de su alto  $R^2$ , presentó un MAPE de 100.57%, indicando que sus errores proporcionales son tan grandes como los valores reales.

SARIMA, aunque con MAPE aceptable, mostró un MAE muy superior y un sesgo sistemático a la baja.

## 7.3 Modelos de Predicción Precios

Para los modelos de los precios de crudo, **XGBoost** demostró un rendimiento sobresaliente, con un  $R^2$  de 0.7889 (explica casi el 79% de la variabilidad) y un MAPE de 3.96%. A pesar de la dramática inversión de la correlación crudo-gas en el período de prueba, el modelo logró adaptarse y mantener predicciones precisas.

LSTM-GRU obtuvo el mejor MAE por un margen mínimo (2.86 vs 2.91), pero su  $R^2$  inferior (0.4976) lo posiciona en segundo lugar.

Prophet fracasó completamente ( $R^2$  negativo), demostrando que los modelos estructurales no pueden manejar cambios de régimen en las relaciones entre variables.

Para los modelos de los precios de gas, **XGBoost** fue el modelo seleccionado, con un MAE de 0.41 USD y un  $R^2$  de 0.5996. La decisión de no incluir el crudo como variable exógena, fundamentada en el análisis de estabilidad de correlación, resultó acertada.

LSTM-GRU presentó un  $R^2$  negativo (-1.666), indicando nula capacidad predictiva, probablemente debido al volumen limitado de datos y la alta volatilidad de la serie.

## 7.4 Hallazgos Importantes

- **Cambios Estructurales en Correlaciones:** El hallazgo más importante del estudio es la identificación de un cambio estructural en la relación crudo-gas, pasando de una correlación positiva fuerte (+0.74) a negativa (-0.56) en el período más reciente. Este fenómeno invalida el supuesto de estabilidad en las relaciones entre variables y tiene implicaciones profundas para la modelización multivariante.
- **Superioridad de XGBoost:** En todos los casos evaluados (producción crudo, producción gas, precio crudo, precio gas), XGBoost fue el modelo seleccionado. Su capacidad para manejar relaciones no lineales, su robustez ante cambios estructurales y su eficiencia con volúmenes moderados de datos lo consolidan como la herramienta más versátil y confiable para este tipo de problemas.
- **Fracaso de Modelos Estadísticos:** Los modelos SARIMA y Prophet, a pesar de su popularidad en la literatura de series temporales, mostraron un desempeño pobre o catastrófico ( $R^2$  negativos) en la mayoría de los casos, evidenciando su incapacidad para adaptarse a la volatilidad y cambios estructurales presentes en los mercados energéticos, puede que su desempeño también no fuera el adecuado debido a que no contaban con más datos para aprender los patrones de las series.
- **Limitaciones del Deep Learning:** Los modelos LSTM-GRU, aunque arquitectónicamente avanzados, no lograron superar a XGBoost en ningún caso, y en varios presentaron  $R^2$  negativos. La principal limitación es el volumen insuficiente de datos (140-144 observaciones) para entrenar redes neuronales profundas de manera efectiva.
- **Importancia del Feature Engineering:** El éxito de XGBoost se fundamenta en un feature engineering exhaustivo pero riguroso, que evita el data leakage mediante shifts y ventanas móviles calculadas exclusivamente con información pasada. Las features más importantes fueron consistentemente los rezagos recientes (lag\_1, lag\_2) y las medidas de volatilidad.

## 7.5 Predicción con Modelos Ganadores

Una vez se seleccionaron y validaron los modelos con los mejores resultados en las métricas de evaluación, se procedió a su **aplicación sobre la totalidad de los datos históricos** para generar las proyecciones definitivas que ayudaran en el análisis para toma de decisiones en el sector.

### 7.5.1 Tendencias de Producción 12 Meses

La proyección para la **producción de crudo** indica una tendencia descendente, esta tendencia es consistente con el agotamiento natural de los campos maduros, la falta de nuevos proyectos de gran escala y los cambios estructurales del gobierno de turno.

La proyección para la **producción de gas** muestra también una tendencia, aunque descendente, no es tan pronunciada como la de crudo, mostrando un leve repunte respecto a los valores de 2025.

El **precio del crudo** por otro lado muestra una recuperación gradual a lo largo del año, comenzando en 62.5 USD/barril en enero y podría llegar a los 68.8 USD/barril, hoy sabemos que el precio sufrió cambios de alza fuertes debido a la guerra que en estos momentos se lleva en Irán, variables que los modelos no pueden incluir.

Para el **precio del gas** se muestra una tendencia decreciente, iniciando en 4.28 USD en enero y descendiendo a 3.29 USD.

### 7.5.2 Estacionalidad Capturada

Las proyecciones de las variables reflejan los patrones estacionales de las series originales que se pudieron identificar durante el análisis exploratorio.

- En crudo, se observan picos en enero, marzo, mayo y agosto, y valles en febrero, abril y junio.
- En gas, los picos se concentran en marzo-abril y los valles en mayo-agosto.

### 7.5.3 Validez de la Proyecciones

Es importante Señalar que estas predicciones representan la **expectativa mas probable** dadas las condiciones históricas y los patrones aprendidos por los modelos, pero pueden estar sujetos a cambios particularmente por eventos geopolíticos y cambios estructurales no anticipados.



## 7.6 Conclusiones Personales

La realización de este proyecto a nivel personal fue desafiante, ha representado para mi un reto profesional y personal, que ha puesto a prueba no solo mis conocimientos en el mundo de los datos, sino también mi capacidad de aprendizaje, adaptación a cambios en proyectos y por supuesto a perseverar.

Al iniciar este proyecto enfrente la dificultad de entrar a un área desconocida, mi formación no es en ingeniería de petróleos ni en economía energética. Trabajar en el sector me daba una visión general, pero carecía del conocimiento profundo necesario para entender como realmente se mueve la producción y los precios del sector energético. Tenia que responder preguntas como ¿Qué factores son relevantes? ¿Por qué la producción se comporta de cierta manera? ¿Qué variables afectan en la producción y en los precios? Estas preguntas no podían ser respondidas solo con datos, requieren comprensión del negocio.

Un punto importante que me ayudo a sacar este proyecto adelante fueron las personas que me brindaron de su tiempo y compartieron conmigo su conocimiento, personas del sector con las que trabajo, ingenieros de petróleos que me explicaron como funciona el declive natural de los pozos, la estacionalidad de la producción, profesionales en finanzas que me ayudaron a comprender el impacto de decisiones geopolíticas y las dinámicas del mercado internacional. Sus aportes fueron muy valiosos para mi y me ayudaron a darle rumbo y sentido al proyecto, logrando interpretar adecuadamente los resultados.

Revisar también trabajos previos, tesis y artículos académicos sobre predicción en el sector energético también me ayudaron a darle rumbo al proyecto, sus errores y alcances me ayudaron a evitar errores comunes, a comprender los modelos estadísticos, ver como se comportan las series volátiles, fueron lecciones importantes en el proyecto.

También tuve momentos difíciles, horas largas tratando de entender porque un modelo no daba buenos resultados, porque el código no funcionaba o porque las métricas no mejoraban, fallas en el pipeline de datos, la incertidumbre de no saber si el enfoque o la metodología era la correcta, a veces con ganas de cambiar de proyecto, pero la ayuda de las personas me permitía continuar con el proyecto.

---

Aprendí varias cosas durante el desarrollo de este proyecto.

- Trabajar con datos temporales fue algo difícil para mí, la validación temporal, el data leakage, la estacionalidad, los cambios estructurales y la volatilidad son conceptos que ahora manejo un poco mejor, pero que se aprenden con la practica y enfrentando casos reales.
- Los proyectos de investigación no son siempre un camino recto, es un camino de pruebas y errores.
- La combinación de datos, conocimiento del negocio y experiencia operativa son importantes para generar resultados realmente valiosos.

Mas allá de los resultados académicos, el proyecto me ayudo en mi camino profesional en el mundo de los datos, ver como los modelos de predicción junto con una buena arquitectura de datos, puede ayudar a las empresas a tomar mejores decisiones en el sector de hidrocarburos y en otros sectores. Se que los modelos tienen limitaciones, pero tomar decisiones basadas en datos es mejor que hacerlos sin ellos.

## CAPITULO 8. FUTURAS LINEAS DE TRABAJO

Este proyecto ha presentado las bases para el desarrollo de capacidades predictivas en el sector de hidrocarburos en Colombia, pero el camino recorrido también ha revelado numerosas oportunidades de mejora y expansión. Las cuales pueden ser.

### 8.1 Análisis con Datos Internos de Operadoras

Una de las limitaciones más significativas del presente estudio fue la dependencia exclusiva de fuentes de datos abiertas (ANH y FRED). Estas plataformas proporcionan información valiosa pero no ayudan para capturar información para capturar dinámicas operativas finas. Las empresas operadoras del sector (ECOPETROL, Geopark, Parex, entre otras) poseen repositorios de datos masivos y detallados que abren posibilidades completamente nuevas:

- Datos diarios de producción por pozo, este proyecto utilizó datos mensuales, las operadoras registran producción diaria, contar con series diarias permitiría entrenar modelos más sofisticados y capturar patrones de alta frecuencia que los datos mensuales promedian y ocultan.
- Existen variables que afectan directamente la producción y que podrían incorporarse como predictores como inyección de agua y gas para mantenimiento de presión en yacimientos, Presión de fondo (PIP) y presión de cabeza, indicadores críticos del comportamiento del pozo, días operativos efectivos por pozo diferenciando entre días de producción normal, mantenimiento o fallas que impactan la producción futura.
- Los equipos de producción (bombas, compresores, separadores) cuentan con sensores que generan streams continuos de datos. Integrar esta información permitiría no solo predecir producción, sino también anticipar fallas en maquinaria que podrían afectar los volúmenes extraídos, abriendo la puerta a estrategias de mantenimiento predictivo.

La incorporación de estos datos internos, sujetos a acuerdos de confidencialidad ya que son datos sensibles y privados, podría elevar la precisión de los modelos a niveles muy superiores a los alcanzados en este estudio.

## 8.2 Automatización y Operaciones

Para que los desarrollos de este proyecto tengan un impacto real en la toma de decisiones, es necesario también cuidar de los procesos:

- Pipeline automatizado de reentrenamiento de modelos asegurando que las predicciones se mantengan actualizadas.
- Desarrollar mecanismos de monitoreo continuo.
- Dashboards interactivos que permitan tomar decisiones y visualizar impactos en tiempo real.

## 8.3 Análisis de Impacto Económico y Social

Aparte de las predicciones técnicas, los resultados pueden utilizarse para análisis de impacto más amplios:

- Utilizar las proyecciones de producción y precios para anticipar los ingresos por regalías que recibirán las entidades territoriales, permitiendo una mejor planificación presupuestal.
- Incorporar los escenarios de precios y producción en la evaluación económica de nuevos proyectos de exploración y producción.

El sector de hidrocarburos representa uno de los pilares fundamentales de la economía colombiana, siendo una de las principales fuentes de ingresos. En este sentido, la capacidad de anticipar el comportamiento de la producción y los precios no es un ejercicio académico, sino una herramienta estratégica.

## Bibliografía

Amazon Web Services. (2023, December 11). *Enhance price capture in energy and commodity trading with AWS machine learning*. AWS for Industries. <https://aws.amazon.com/blogs/industries/enhance-price-capture-in-energy-and-commodity-trading-with-aws-machine-learning/>

Amazon Web Services. (2019, August 7). *Kinect Energy uses Amazon SageMaker to Forecast energy prices with Machine Learning*. AWS Machine Learning Blog. <https://aws.amazon.com/blogs/machine-learning/kinect-energy-uses-amazon-sagemaker-to-forecast-energy-prices-with-machine-learning/>

Cloudar. (2024, September 16). *iCAT - Precision Energy Price Forecasting*. AWS Case Study. <https://cloudar.be/case-studies/icat-precision-energy-price-forecasting/>

AspenTech. (2025, February 19). *S&P Global Commodity Insights Creates Sustainable Value for the Oil Industry*. AspenTech Blog. <https://solutions.aspentech.com/ru/resources/blog/sp-global-commodity-insights-creates-sustainable-value-for-the-oil-industry>

gps31320779. (2024). *insightflow-retail-economic-pipeline* [Portfolio project]. GitHub. <https://github.com/gps31320779/insightflow-retail-economic-pipeline>

Armbrust, M., Das, T., Paranjpye, S., Xin, R., Zhu, S., Ghodsi, A., Yavuz, B., Murthy, M., Torres, J., Sun, L., Boncz, P. A., Mokhtar, M., et al. (2020). Delta Lake: High-performance ACID table storage over cloud object stores. *Proceedings of the VLDB Endowment*, 13(12), 3411-3424. <https://dl.acm.org/doi/10.14778/3415478.3415560>

Hashem, I. A. T., Yaqoob, I., Anuar, N. B., Mokhtar, S., Gani, A., & Khan, S. U. (2015). The rise of "big data" on cloud computing: Review and open research issues. *Information Systems*, 47, 98-115. <https://www.sciencedirect.com/science/article/abs/pii/S0306437914001288>

Amazon Web Services. (2023). *AWS Well-Architected Framework*. AWS Whitepapers. Recuperado de <https://aws.amazon.com/architecture/well-architected/>

---

Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley. [Libro físico disponible en editoriales y librerías académicas]